저궤도 우주 방사선 단일 사건 오류(SEU)가 인공신경망 가중치에 미치는 영향

— 모델 크기 · 선량 · 방어에 따른 생존률의 측정과 예측 모형 —

이태린[1] 최재원[2] 조교: 이유림[3] 지도교사: 이성진[3]

[1] 민락중학교 [2] 선덕중학교 [3] 대진대학교

2026년 10월

초록

저궤도(LEO) 위성에 탑재된 인공지능은 우주 방사선이 메모리의 비트 하나를 뒤집는 단일 사건 오류(single-event upset, SEU)에 노출된다. 본 연구는 가우시안 잡음이 아니라 IEEE 754 float32 가중치의 비트 하나를 실제로 XOR 하는 시뮬레이터를 구현하고, MNIST 손글씨 분류 신경망(가중치 101,632개, 3,252,224비트)에 대해 가중치당 비트플립 확률 p를 10^{-5}에서 10^{-1}까지 13단계로 바꾸며(각 10회, 총 260회 시행) 정확도를 p의 함수로 측정하였다. 방어가 없을 때 정확도는 p에 따라 매끄럽게 감소하지 않고, 같은 p에서도 거의 무손상인 시행과 붕괴한 시행이 공존하는 이봉(bimodal) 분포를 보였다. 생존률(무손상 정확도의 90 % 이상 유지)이 50 %로 떨어지는 확률은 방어 없음에서 $p \approx 0.055\,\%$, 가장 단순한 방어인 가중치 클리핑(NaN/∞ 제거 후 $[-3, 3]$으로 절단)에서 $p \approx 5.61\,\%$로, 클리핑은 견딜 수 있는 선량을 약 102배 높였다. 명중한 비트의 25.0 %만이 지수부였음에도 붕괴를 지배한 것은 지수부 명중이었으며, 이는 float32의 구조로 설명된다. 작은 오차는 깊이에 무관하게 크기가 보존되어 무해하지만, 지수 최상위 비트 하나가 만든 10^{38} 크기의 값은 한 층만 지나도 출력 전체를 지배한다. 결과를 상용 메모리의 궤도 측정값 수준인 SEU 발생률 $r = 10^{-6}$/bit/day(메모리 1 GB당 하루 약 8,600회)로 LEO 노출 일수에 환산하면, 방어 없는 모델은 약 17일, 클리핑 모델은 약 1754일에 생존률 50 %에 도달한다. 합성곱 모델과 ResNet-18까지 가중치 수가 110배 차이 나는 네 모델에 같은 실험을 반복한 결과, 생존률 50 %에 해당하는 명중 수는 60–110개로 거의 일정하였다. 생존을 결정하는 것은 확률이 아니라 뒤집힌 비트의 개수이므로, 궤도에서 버티는 시간은 모델 크기에 반비례하며 ResNet-18급 모델은 방어 없이 하루를 넘기지 못한다. 이를 "명중 하나가 치명적일 확률 q"로 요약한 수학 모형 $S = e^{-qk}$는 $q = \frac{1}{32}\pi_{+}\alpha$(지수 최상위 비트 선택 확률 × 양수 가중치 비율 × 유효 전파 비율)로 거의 설명되며, stress 모드로 맞춘 모형이 SAA 통과에 명중이 몰리는 궤도 모드(E3)의 생존률을 평균 오차 0.06로 예측하였다. 단일 비트 실험(E2)에서는 32비트 가운데 지수 최상위 비트(bit 30)만 치명적이었고, 그 단일 명중 생존률(0.74)은 모형의 예측 $1 - 32q$(0.72)과 일치하였다. 방어 6종 비교(E5)에서 패리티와 TMR은 $p \le 3\,\%$에서 무손상, 클리핑은 약 100배, 로짓 중앙값 앙상블은 2배의 이득을 보였고, 로짓 평균 앙상블은 방어 없음보다 나빴다. TMR의 한계 $k_{50} \approx \sqrt{32 N_w \ln 2/(3q)}$를 유도하여 고선량 실험으로 확인하였다.

주요어: 단일 사건 오류(SEU), 비트플립, 부동소수점, 인공신경망, 내결함성, 저궤도, 클리핑

1 서론

1.1 연구 배경

지구 자기장과 대기의 보호를 벗어난 우주에서는 고에너지 양성자와 중이온이 반도체 메모리 셀에 전하를 남겨 저장된 비트 값을 뒤집는다. 이러한 단일 사건 오류(SEU)는 영구 손상이 아니라 "한 비트가 0에서 1로, 또는 1에서 0으로 바뀌는" 일시적 오류이며, 저궤도에서는 특히 남대서양 이상 지역(South Atlantic Anomaly, SAA)을 통과할 때 집중적으로 발생한다 [1–3]. 최근 위성 영상의 궤도상 판독, 자율 항법 등을 위해 인공신경망을 위성에 직접 탑재하려는 시도가 늘고 있으므로, SEU가 신경망의 가중치를 뒤집었을 때 무슨 일이 일어나는지는 실용적으로 중요한 질문이다.

1.2 연구 목적과 질문

본 연구의 목적은 궤도 측정값 수준의 *SEU* 선량을 중심으로 선량을 넓게 바꾸면서, 크기가 다른 신경망의 정확도가 어떻게 무너지는지, 무엇이 그것을 결정하는지, 여러 방어가 버티는 시간을 얼마나 늘리는지를 정량화하고, 그 결과를 모델·선량·방어의 함수로 예측하는 수학적 모형을 세우는 것이다. 구체적인 질문은 다음과 같다.

Q1. 선량 축. 비트플립의 양(가중치당 확률 p, 또는 궤도 노출 일수 T)이 늘어날 때 정확도는 어떤 모양으로 감소하는가? 선형인가, 임계점이 있는가? 같은 선량에서도 결과가 시행마다 크게 다른가?

Q2. 모델 축. 가중치 수가 100배 넘게 다른 모델들에서 이 관계는 어떻게 달라지는가? 무엇이 생존을 결정하는가?

Q3. 방어 축. 클리핑·패리티·TMR·앙상블은 각각 버틸 수 있는 선량을 몇 배 늘리는가?

Q4. 예측. 모델 크기, 선량, 방어가 주어졌을 때 생존률과 생존 시간을 계산할 수 있는 간단한 수식이 있는가? 그 수식은 맞추지 않은 조건(궤도 시간 구조)에서도 맞는가?

이에 대한 가설은 다음과 같다.

- **H1.** p가 커질수록 정확도는 낮아진다(음의 상관).
- **H2.** 정확도는 p에 대해 완만히 감소하지 않고, 어떤 구간을 넘으면 급격히 무너지는 임계 구간이 존재한다.
- **H3.** 붕괴는 뒤집힌 비트의 개수보다 위치(지수부 여부)에 좌우되므로, 지수부 명중이 만드는 $\pm\infty$와 거대 값을 잘라내는 클리핑만으로도 생존 가능한 선량이 크게 늘어난다.
- **H4.** 명중 하나가 치명적일 확률 q는 모델의 크기·구조와 무관하게 거의 일정하고, 따라서 생존률은 명중 수 k의 지수함수 e^{-qk}를 따른다.
- **H5.** H4가 맞다면, 같은 비트플립 확률 p 또는 같은 궤도 노출 시간에서는 큰 모델이 먼저 무너진다. 명중 수가 $k = pN_w$(N_w는 뒤집힐 수 있는 가중치의 수), 하루 명중 수가 rN_{bits}($N_{\text{bits}} = 32N_w$)로 모델 크기에 비례하기 때문이다. 이는 "가중치가 많은 큰 모델은 중복성이 커서 더 강건하다"는 통념과 반대되는 예측이다. 중복성은 작은 교란(가수부 플립)만 흡수할 뿐, 10^{38} 크기의 지수부 플립은 가중치가 아무리 많아도 묻히지 않는다는 것이 그 근거다.

1.3 연구의 특징

기존의 신경망 내결함성 연구 [4–9]는 주로 가속기 하드웨어 설계나 보안 공격 관점에서 수행되었다(5.3절에서 정량 비교). 본 연구는 손상을 넣는 방법, 재는 방법, 읽는 방법의 세 단계에서 각각 선택을 달리했다. (i) 넣는 방법: 가우시안 잡음 모델이 아닌 진짜 비트 XOR을 쓴다. 잡음 모델은 모든 가중치를 조금씩 흔들지만, 실제 SEU는 가중치 하나의 비트 하나를 바꾸며 그 결과가 비트 위치에 따라 10^{-7}배에서 10^{38}배까지 달라진다. (ii) 재는 방법: (i)의 결과로 같은 조건에서도 시행이 "거의 무손상"과 "붕괴"의 두 무리로 갈라지므로, 평균±표준편차 대신 중앙값·사분위범위·생존률·붕괴율로 요약한다. 평균은 두 무리 사이의, 아무 시행도 겪지 않은 값을 보고하게 된다. (iii) 읽는 방법: 비트플립 확률을 궤도 측정 SEU 율로 LEO 노출 일수에 환산하고, 모델 크기에 따라 그 일수가 어떻게 달라지는지를 수학 모형으로 예측한다. 또한 모든 코드는 CPU에서 수 분 안에 재현 가능하도록 공개한다.

2 배경 이론

2.1 IEEE 754 float32와 비트 위치의 치명도

신경망 가중치는 보통 32비트 부동소수점(float32)으로 저장된다 [10]. 그림 1처럼 32비트는 부호 1비트(bit 31), 지수 8비트(bit 30–23), 가수 23비트(bit 22–0)로 나뉘며, 값은

$$w = (-1)^S \times 2^{E-127} \times \left(1 + \frac{M}{2^{23}}\right) \tag{1}$$

이다. 따라서 어느 비트가 뒤집히느냐에 따라 피해 규모가 전혀 다르다. 가수의 낮은 비트는 값을 10^{-7} 수준으로만 바꾸지만, 지수 최상위 비트(bit 30)가 $0 \to 1$로 뒤집히면 2^{E-127}이 2^{E+1}이 되어 가중치가 약 $2^{128} \approx 3.4 \times 10^{38}$배로 커지거나 $\pm\infty$가 된다.

> **예 1** (1.0의 비트 하나를 뒤집으면). 1.0은 $S = 0$, $E = 127$, $M = 0$이므로 비트열은 `0 01111111 000…0`, 16진수로 `0x3F800000`이다. 여기서 비트 하나씩만 뒤집어 보면 다음과 같다.
>
> - bit 0(가수 최하위) $\to$ `0x3F800001` $= 1 + 2^{-23} \approx 1.0000001$. 상대오차 1.2×10^{-7}, 사실상 무해.
> - bit 22(가수 최상위) $\to$ `0x3FC00000` $= 1.5$. 가수 비트 중 가장 큰 변화지만 2배 미만.
> - bit 31(부호) $\to$ `0xBF800000` $= -1.0$. 크기는 그대로, 부호만 반전.
> - bit 30(지수 최상위) $\to$ `0x7F800000`. 지수가 11111111이 되어 $+\infty$. 1.0이 아니라 0.99였다면 $E = 126$이어서 ∞ 대신 $1.98 \times 2^{127} \approx 3.4 \times 10^{38}$이 된다.
>
> 즉 32비트 중 31개는 값을 2배 이내로 바꾸거나 부호만 바꾸고, bit 30 하나만 10^{38}배 또는 ∞를 만든다.

> **노트 1** (**float32**에 ∞와 **NaN**이 있는 이유). IEEE 754가 $\pm\infty$와 NaN(Not a Number)을 둔 것은 "계산이 중간에 멈추지 않고 끝까지 가되, 문제가 생겼다는 사실은 결과에 남게 하자"는 설계이다. (1) ∞는 넘침(overflow)을 위한 값이다. float32의 최댓값은 약 3.4×10^{38}인데, 그보다 큰 결과가 나왔을 때 프로그램을 멈추거나 틀린 값으로 되돌아가는(정수 overflow처럼) 대신 "너무 커서 표현 못 함"을 뜻하는 ∞를 돌려준다. $1/0 = \infty$, $1/\infty = 0$처럼 극한과 일치하는 산술이 이어진다. (2) NaN은 답이 정해지지 않는 연산을 위한 값이다. $0/0$, $\infty - \infty$, $0 \times \infty$, $\sqrt{-1}$은 어떤 수로도 답할 수 없으므로 NaN을 돌려주고, NaN이 섞인 모든 연산은 다시 NaN이 된다. 그래서 긴 계산의 어디에서 문제가 생겼든 최종 결과에 NaN이 남아 "무효"임을 알 수 있다(NaN은 자기 자신과도 같지 않아 검사할 수 있다). (3) 비트 배치에서는 지수 8비트가 모두 1인 패턴($E = 255$)을 수로 쓰지 않고 이 특수값에 예약하였다. 가수가 0이면 $\pm\infty$, 0이 아니면 NaN이다. 그래서 지수의 최댓값은 $E = 254$(2^{127})까지이다.
>
> 이 예약이 본 연구와 직접 이어진다. 1.0(지수 01111111)의 bit 30을 뒤집으면 지수가 11111111이 되어 수가 아닌 $+\infty$가 되는 것(예 1)이 그 때문이고, ∞가 로짓에 들어가면 softmax에서 $\infty - \infty = \text{NaN}$이 생겨 전파 규칙에 따라 출력 전체가 NaN이 된다. 본 논문의 "붕괴" 지표(3.3절)는 이 전파 성질을 그대로 이용한 것이며, 클리핑 방어의 첫 단계가 `nan_to_num`인 이유도 NaN을 그대로 두면 아무리 작은 비율이라도 결과 전체가 무효가 되기 때문이다.

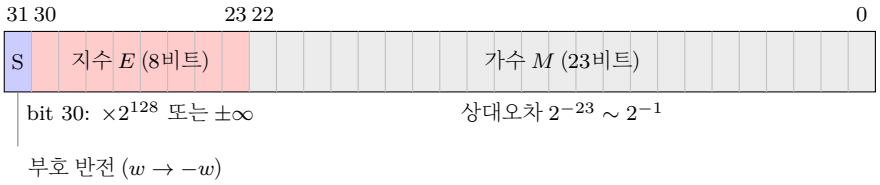


그림 1. float32의 비트 배치와 비트플립의 효과. 지수부는 전체의 25 %(8/32)에 불과하지만 피해의 대부분을 만든다.

2.2 오차 전파: 증폭이 아니라 크기 보존

신경망은 일차함수 $y = Wx + b$와 활성화 함수를 층층이 쌓은 구조이다. 어느 층에서 생긴 작은 오차 δ는 그 뒤의 층들을 지나며 출력에 $\delta y \approx J\,\delta$만큼 나타난다. 여기서 $J = W_n D_n \cdots W_{l+1} D_{l+1}$은 그 층 이후의 야코비안이고 D는 활성화 함수의 미분(ReLU에서는 0 또는 1)이다. 즉 오차는 신호와 같은 행렬들을 통과하므로, 오차의 배율은 신호의 배율과 같다. 학습된 신경망은 입력 신호가

층을 지나며 폭발하거나 사라지지 않도록 초기화되고 학습되므로 이 배율은 대체로 1 안팎이며, 1차원 곱셈 릴레이 $\delta \cdot a^n$처럼 깊이에 따라 지수적으로 커지거나 작아지지 않는다. 수업 10주차의 "나비효과" 실험은 이 점을 과장한 교육용 모형이다. 실제로 본 연구의 E2에서 가수부 플립(상대 오차 10^{-7}–1)은 2층 모델부터 18층 ResNet까지 어느 깊이에서도 정확도를 바꾸지 못했다.

따라서 피해는 오차가 자라서가 아니라 처음부터 거대해서 생긴다. 지수 최상위 비트 명중으로 생긴 10^{38} 크기의 값은 배율 1로 전파되어도 다음 층의 합을 혼자 지배하고, 그 값이 들어간 로짓은 softmax에서 ∞가 된다. $\infty - \infty = \mathrm{NaN}$, $0 \times \infty = \mathrm{NaN}$이므로 출력 전체가 NaN이 되어 모든 예측이 무효가 되며, 학습 중이라면 NaN 그래디언트가 모든 가중치를 덮어쓴다. 깊이가 피해를 키우는 것은 아니지만, 한 층만 지나도 피해가 완성된다는 뜻이다.

2.3 방어 기법

- **클리핑(clipping)**: $w \leftarrow \mathrm{clip}(\mathrm{nan_to_num}(w), -C, +C)$. NaN은 0, $\pm\infty$와 범위를 넘는 값은 $\pm C$로 잘라낸다. 비트플립 자체를 막지는 못하지만 ∞/NaN의 전파를 끊는다. 활성값 클리핑으로 내결함성을 높인 선행 연구 [7]와 같은 발상이며, 본 연구는 이를 가중치에 적용하였다($C = 3$).
- **삼중 모듈 중복(TMR)**: 같은 값을 세 벌 저장하고 중앙값을 취한다 [11]. 중앙값은 한 벌이 ∞가 되어도 영향을 받지 않는다.
- **앙상블(ensemble)**: 독립적으로 손상된 모델 여러 개의 출력을 평균한다. 평균은 유한하지만 거대한 이상치 하나에도 무너지므로($\mathrm{mean}(42, 42, 10^{38}) \approx 3 \times 10^{37}$), 중앙값 앙상블이 더 강건하다.
- **패리티(parity)**: 32비트의 1의 개수가 짝수가 되도록 1비트를 추가 저장하고, 불일치가 발견된 가중치를 0으로 되돌린다. 1비트 오류의 검출은 가능하나 정정은 불가능하다.

> **노트 2 (TMR과 앙상블: 무엇을 어디서 합치는가).** TMR과 앙상블은 "여러 벌을 두고 합친다"는 점은 같지만, 무엇을 어디서 합치느냐가 다르다. TMR은 가중치 W를 세 벌 저장하고, 각 벌이 독립적으로 명중된 뒤 추론 전에 가중치 하나하나마다 세 값의 중앙값을 취해 W 하나로 만든다(디지털 회로의 TMR은 비트 단위 다수결이지만 float32 값은 완전히 같아야 "표"가 되므로 중앙값을 쓴다). 추론은 한 번이고 메모리는 3배이다. 앙상블은 모델 전체를 다섯 벌 두고 각각 추론을 마친 뒤 출력 로짓을 평균(ensemble) 또는 원소별 중앙값(ensemble_median)으로 합친다. 추론 5회, 메모리 5배이다.
>
> 차이는 손상이 어디까지 퍼진 뒤 합치느냐에서 온다. TMR은 손상이 퍼지기 전에 막는다. 어느 가중치가 한 벌에서 10^{38}이 되어도 다른 두 벌이 정상이면 중앙값은 정상값이고, 이후 추론은 무손상과 같다. 한 가중치가 망가지려면 세 벌 중 둘 이상이 같은 가중치에서, 둘 다 치명 비트를 맞아야 하므로 기대 치명 수가 k가 아니라 k^2에 비례한다(명제 2, 3.5절). 앙상블은 각 모델이 끝까지 추론한 뒤 합치므로, 치명 명중을 받은 모델의 로짓은 이미 10^{38} 크기이거나 NaN이다. 평균을 쓰면 그 하나가 나머지 넷을 삼켜 다섯 중 하나라도 치명이면 전체가 죽는다(생존률 S^5, 이득 1/5). 중앙값을 쓰면 다섯 중 셋 이상이 통째로 살아 있어야 한다. 모델 하나가 죽을 확률 $1 - S$는 가중치 하나가 두 벌에서 겹쳐 맞을 확률과 비교할 수 없이 크므로, 같은 "중앙값"이라도 가중치 수준의 TMR이 모델 수준의 앙상블보다 훨씬 강하다. E5(4.8절)에서 TMR은 $p = 3\,\%$까지 무손상, 중앙값 앙상블은 이득 약 2배, 평균 앙상블은 방어 없음보다 나빴다. 앙상블이 뜻을 갖는 것은 가중치에 손댈 수 없는 상용 가속기나 블랙박스 모델에서 출력만 받아 합칠 수 있을 때이며, 그때도 반드시 평균이 아니라 중앙값이어야 한다.

3 연구 방법

3.1 비트플립 시뮬레이터

본 연구에서 구현한 시뮬레이터(`seu_suite`, PyTorch [12] 기반)는 모델의 모든 2차원 이상 가중치 텐서(행렬·합성곱 커널)를 하나의 float32 "가중치 은행"으로 본다. 은행의 원소 수를 N_w, 비트 수를 $N_{\mathrm{bits}} = 32N_w$라 하고, 각 사건을 (가중치 번호 0–$N_w-1$, 비트 번호 0–31)의 쌍으로 정의한다. 가중치 텐서를 `uint32` 뷰로 바라본 뒤 해당 비트 하나만 XOR 하므로 메모리 제자리에서 값이 바뀐

다. 핵심은 목록 1의 세 줄이다. (1) 가중치 텐서를 복사 없이 numpy 배열로 얻고, (2) 그 바이트를 부호 없는 32비트 정수로 다시 읽은 뒤(`view`), (3) 원하는 비트 자리에 1을 XOR 한다. 메모리를 공유하므로 모델의 가중치가 제자리에서 바뀐다. 예 1의 두 경우(1.0의 bit 31 $\rightarrow -1.0$, bit 30 $\rightarrow +\infty$)를 자가진단으로 매 실행마다 확인한다. 편향(1차원 텐서)은 기본적으로 뒤집지 않는다.

목록 1. 비트플립의 핵심: numpy → view → XOR 세 단계(`src/radiation.py`의 `xor_one_bit`을 줄인 것).

```
w = weight.detach().numpy()           # (1) numpy: shares memory, no copy
u = w.view(np.uint32).ravel()         # (2) view : same bytes as uint32
u[i] ^= np.uint32(1) << np.uint32(b)  # (3) xor  : flip bit b of weight i

# 1.0 = 0x3F800000 ; bit31 -> 0xBF800000 = -1.0 ; bit30 -> 0x7F800000 = +inf
```

방사선 모드는 세 가지이다.

- **stress**: 각 가중치를 독립적으로 확률 p로 명중시키고, 명중한 가중치의 무작위 비트 하나를 뒤집는다. 시간 개념이 없는 가속 실험으로, 기대 명중 수는 $\mathbb{E}[k] = p\,N_w$이다.
- **poisson**: 발생률 r [SEU/bit/day]로 노출 시간 T [day] 동안의 창 $[0, T]$에서 균일한 푸아송 과정. 기대 명중 수는 $\lambda = r\,N_{\text{bits}}\,T$ [SEU].
- **leo_saa**: 하루에 SAA 통과 3회(각 12분)를 두고 하루 SEU의 90 %를 통과 구간에 몰아넣은 비균일 푸아송 과정(통과 중 발생률 $\approx 36r$, 평시 $\approx 0.10r$, 노트 3).

> **노트 3 (SAA 통과 중 발생률 $36r$과 평시 $0.10r$의 계산).** 하루 평균 발생률이 r이면 하루의 기대 명중은 비트당 $r \times 1$일이다. 통과 구간은 $3 \times 12 = 36$분으로 하루 1440분의 $36/1440 = 1/40 = 2.5\,\%$이고, 여기에 하루 명중의 90 %를 넣는다. 통과 중 발생률을 r_{saa}라 하면 $r_{\text{saa}} \times \frac{36}{1440} = 0.9\,r$이므로
>
> $$r_{\text{saa}} = 0.9 \times \frac{1440}{36}\,r = 0.9 \times 40\,r = 36\,r.$$
>
> 나머지 10 %는 평시 $1440 - 36 = 1404$분에 고르게 퍼지므로 $r_{\text{quiet}} \times \frac{1404}{1440} = 0.1\,r$, 즉
>
> $$r_{\text{quiet}} = 0.1 \times \frac{1440}{1404}\,r \approx 0.1026\,r \approx 0.10\,r.$$
>
> 검산하면 $36r \times 0.025 + 0.1026r \times 0.975 = 0.9r + 0.1r = r$로 하루 평균이 보존된다. 통과 중 발생률은 평시의 약 350배이며, 12분 통과 한 번에 들어오는 명중은 하루 전체의 30 %(0.9/3)이다. 예컨대 `mnist_linear`($N_{\text{bits}} = 3,252,224$)는 $r = 10^{-6}$에서 하루 약 3.25개를 받으므로 통과 한 번에 약 1개, 평시 23.4시간 동안 약 0.3개꼴이다.

본 논문의 주 실험(E1)은 stress 모드만 사용하였다. 결과 해석을 위해, stress 모드의 기대 명중 수 $p\,N_w$와 궤도 노출 T일의 기대 명중 수 $r\,N_{\text{bits}}\,T$를 같게 놓아, p와 같은 기대 명중 수를 주는 LEO 노출 일수를

$$T_{\text{eq}} = \frac{p\,N_w}{r\,N_{\text{bits}}} = \frac{p}{32\,r} \tag{2}$$

로 정의한다($N_{\text{bits}} = 32N_w$). 발생률 r은 상용 메모리의 궤도 측정값을 따른다. 고도 686 km의 Alsat-1 위성에 실린 상용 SRAM은 약 10^{-6}/bit/day(80 %가 단일 비트 오류)를 기록하였고 [13], 고도 1,336 km의 JASON-2 위성 CARMEN-2 실험의 3년 기록은 약 4.8×10^{-7}/bit/day에 해당한다 [14, 15]. 메모리 1 GB(8.6×10^9 비트)로 환산하면 하루에 약 4,100~8,600회의 비트플립이며, 지상(약 한 달에 몇 회)보다 네 자릿수 이상 많다. 본 논문은 이 범위의 윗값인 $r = 10^{-6}$/bit/day를 기본값으로 쓴다. 이 환산은 기대값만 맞춘 것이며, 명중이 SAA 통과에 몰리는 실제 궤도 모드에서도 같은 결론이 나오는지는 E3(4.7절)에서 따로 확인한다.

노트 4 (p와 r의 차이). p와 r은 종류가 다른 양이다. p는 시간 개념이 없는 시뮬레이터 설정값으로, 가중치 하나가 명중될 확률이며 기대 명중 수는 $p\,N_w$이다. 반면 r은 궤도에서 측정되는 물리량으로, 메모리 비트 하나가 하루에 뒤집힐 확률[SEU/bit/day]이며, 모델 전체 $N_{\text{bits}} = 32N_w$ 비트를 T일 노출하면 기대 명중 수는 $r\,N_{\text{bits}}\,T$이다. 식 (2)는 두 기대 명중 수를 같게 놓은 것이다. N_w가 약분되므로 T_{eq}는 모델 크기와 무관하고, p에 비례하며 r에 반비례한다.

예 2 (그림 2의 위쪽 축 읽기). $r = 10^{-6}$/bit/day이면 $T_{\text{eq}} = p/(3.2 \times 10^{-5})$이므로 $p = 0.0032\,\%$가 하루, $p = 0.01\,\%$가 약 3일, 생존률 50 %의 $p = 0.055\,\%$가 약 17일에 해당한다. 그림 2의 위쪽 축이 이 환산이다. 다만 r은 고도·메모리 종류·태양 활동에 따라 수 배씩 달라지므로, 위쪽 축의 눈금은 "$r = 10^{-6}$을 가정했을 때"의 값이다. 다른 r을 쓰면 아래 축(p)과 곡선은 그대로이고 위쪽 축의 일수만 $1/r$에 비례해 늘거나 줄어든다. 예컨대 JASON-2 값 4.8×10^{-7}을 쓰면 모든 일수가 약 2.1배가 된다.

3.2 모델과 데이터

주 실험(E1)의 모델은 MNIST 손글씨 데이터 [16](학습 60,000장, 시험 10,000장)에 대해 $784 \to 128 \to 10$의 2층 완전연결 신경망(ReLU)을 SGD(학습률 0.05, 모멘텀 0.9, 배치 128)로 2 epoch 학습한 것이다. 깨끗한 모델의 시험 정확도는 96.66 %이며, 이 가중치를 체크포인트로 저장해 모든 시행이 같은 출발점에서 시작하도록 하였다. 뒤집을 수 있는 가중치는 $N_w = 101,632$개, $N_{\text{bits}} = 3,252,224$비트이다.

이 모델은 문헌 [8]의 MNIST 완전연결 기본 모델과 같은 부류이며, 시행 하나가 1초 미만이라 13단계 선량에 10회 반복이 가능하다는 점에서 선택하였다. 그러나 2층 구조로는 깊이가 결과에 영향을 주는지 알 수 없고, MNIST는 클래스 간 여유가 커서 손상에 관대하며, 무엇보다 LEO 일수 환산이 모델 크기에 반비례한다. 그래서 모델 크기 축(E1-M)으로 표 1의 세 모델을 추가하였다. 합성곱 모델 `mnist_cnn`, CIFAR-10의 6층 합성곱 모델 `cifar_deep`(학습 10,000장, 6 epoch), 그리고 ImageNet 사전학습 ResNet-18 [17](torchvision 배포 가중치 [18])의 백본을 고정하고 마지막 층만 CIFAR-10(32×32, 학습 10,000장, 8 epoch)에 학습한 `resnet18_t10`이다. MNIST 모델은 시험 10,000장 전체로 평가하고, CIFAR-10 두 모델은 실행 시간을 줄이기 위해 시험 집합의 앞 2,000장으로 평가한다(모든 시행에 같은 2,000장). 여기서 백본(backbone)이란 입력 영상에서 특징(feature)을 뽑아내는 신경망의 앞부분 전체를 말한다. ResNet-18에서는 첫 합성곱층, 잔차 블록 8개(합성곱층 16개)와 배치정규화층이 백본이고, 그 끝에 붙은 완전연결층 $512 \to 10$이 분류기(head)이다. 본 연구는 백본의 가중치 약 1,117만 개를 ImageNet에서 학습된 값 그대로 고정하고(`requires_grad=False`), 분류기의 파라미터 5,130개만 CIFAR-10으로 학습하였다. 입력은 32×32를 224 × 224로 키우지 않고 그대로 넣었으므로(CPU 예산) 무손상 정확도가 낮다. 그러나 비트플립은 고정된 백본을 포함한 모든 2차원 이상 가중치에 가해지므로 N_w는 백본을 포함한 11,172,032개이다. 따라서 `resnet18_t10`의 가중치 비트는 대부분 배포된 사전학습 값이고, 나머지 세 모델의 가중치는 본 연구에서 처음부터 학습한 값이다. 표 1에 네 모델의 구조·데이터·파라미터를 정리하였다. 모든 깨끗한 체크포인트는 저장소에서 재생성할 수 있다. 뒤의 두 모델은 CPU 예산 때문에 무손상 정확도가 낮지만(각 54.6 %, 39.1 %), 생존률은 무손상 대비로 재므로 모델 크기 효과를 보는 데는 충분하다.

표 1. 실험에 사용한 네 모델의 구조·데이터·파라미터. "학습 대상"은 본 연구에서 SGD로 갱신한 파라미터 수, N_w는 비트플립 대상(2차원 이상 텐서의 원소; 편향과 배치정규화 파라미터는 1차원이라 제외), $N_{\text{bits}} = 32N_w$이다. `resnet18_t10`의 배치정규화 통계(9,620개)는 파라미터가 아니므로 뒤집지 않는다.

모델	구조 (데이터)	데이터(장)		epoch/	파라미터	N_w	무손상
		학습	시험	lr/배치	(학습 대상)		정확도(%)
`mnist_linear`	FC 784–128–10 (MNIST)	60,000	10,000	2/0.05/128	101,770 (전부)	101,632	96.7
`mnist_cnn`	Conv×2, FC×2 (MNIST)	60,000	10,000	2/0.05/128	220,234 (전부)	220,064	98.7
`cifar_deep`	Conv×6, FC (CIFAR-10)	10,000	2,000	6/0.05/64	307,498 (전부)	307,040	54.6
`resnet18_t10`	ResNet-18 고정+FC (CIFAR-10)	10,000	2,000	8/0.01/64	11,181,642 (5,130)	11,172,032	39.1

3.3 측정 지표

시행마다 다음을 기록한다.

- **정확도**(acc): 손상된 모델의 MNIST 시험 정확도(%).
- **붕괴**(crashed): 가중치 또는 출력 로짓에 NaN/∞가 하나라도 있으면 1. 붕괴한 시행의 정확도는 찍기 수준(10 %)으로 기록한다.
- **생존**(survived): 붕괴하지 않고 acc $\geq 0.9\times$ 무손상 정확도이면 1.
- 명중 수 k, 그중 지수부(bit 23–30) 명중 수와 부호(bit 31) 명중 수.

결과가 이봉 분포를 이루므로, 조건별 요약에는 평균 대신 중앙값, 사분위범위(IQR), 생존률, 붕괴율을 사용한다.

3.4 실험 설계 (E1: p에 따른 정확도)

조작 변수는 $p \in \{10^{-5}, 3\times10^{-5}, 10^{-4}, 3\times10^{-4}, 10^{-3}, 2\times10^{-3}, 3\times10^{-3}, 5\times10^{-3}, 10^{-2}, 2\times10^{-2}, 3\times10^{-2}, 5\times10^{-2}, 10^{-1}\}$의 13단계와 방어 $\in$ {없음, 클리핑}의 2수준이며, 각 조건을 10회 반복하였다(총 260회). 통제 변수는 모델·체크포인트·시험 데이터·허용 비트(0–31 전부)이다. 모든 시행은 마스터 시드 2026에서 유도된 고유 시드를 CSV에 기록하여 재현 가능하다. 시행 하나의 비트플립과 평가에는 CPU에서 최대 0.26초가 걸렸다.

모델 크기 축(E1-M)은 같은 절차를 `mnist_cnn`, `cifar_deep`, `resnet18_t10`에 반복한 것이다. p는 10^{-5}에서 10^{-1}까지 9단계(`resnet18_t10`은 가중치 수가 많아 10^{-6}에서 10^{-2}까지), 방어 2수준, 각 10회이다. 모델 간 비교에는 무손상 대비 정확도와 생존률을 쓰고, 가로축으로 p 외에 기대 명중 수 $\bar{k} = pN_w$를 함께 쓴다.

E3 (궤도 모드). `leo_saa` 모드, $r = 10^{-6}$/bit/day에서 방어 2수준, 각 10회를 돌렸다. 노출 일수는 `mnist_linear`와 `mnist_cnn`에서 $T \in \{1, 3, 7, 14, 30, 60, 90\}$, 하루 명중이 357개인 `resnet18_t10`에서 $T \in \{0.03, 0.1, 0.3, 1, 3\}$으로 두었다. stress 모드와 달리 명중이 SAA 통과 구간에 몰려 들어오며, 하루 미만의 T에서는 통과 횟수가 0 또는 1로 추첨되어 시행 간 선량 차이가 크다. 이 데이터는 수학 모델의 피팅에 쓰지 않고 검증에만 쓴다.

E5 (방어 비교). `mnist_linear`에 $p \in \{10^{-5}, 3\times10^{-5}, 10^{-4}, \ldots, 10^{-2}, 3\times10^{-2}\}$(8단계), 방어 6종(없음, 클리핑, 패리티, TMR, 로짓 중앙값 앙상블, 로짓 평균 앙상블), 각 10회이다. TMR은 복제본 3개, 앙상블은 5개를 각각 독립적으로 손상시키므로 시스템 전체가 받는 명중 수는 3배·5배이다.

3.5 수학적 모델

결과를 모델·선량·방어의 함수로 예측하기 위해 두 모형을 세운다.

모델 A (치명 명중 모형, 방어 없음). 명중 하나가 모델을 무너뜨릴("치명") 확률을 q라 하면, k번 명중 후 치명 명중이 하나도 없을 확률이 생존률이다.

$$S(k) = (1-q)^k \approx e^{-qk}, \qquad S(T) = \exp\big(-q\,r\,N_{\text{bits}}\,T\big), \qquad T_{50} = \frac{\ln 2}{q\,r\,N_{\text{bits}}}. \tag{3}$$

2.1절의 분석에 따라 q는 세 인자의 곱

$$q = \tfrac{1}{32}\,\pi_+\,\alpha \tag{4}$$

으로 분해된다(노트 5). π_+는 체크포인트에서 직접 재고(0.42–0.49), α만 데이터로 맞춘다.

노트 5 (q의 세 인자). 명중 하나가 치명적이려면 세 조건이 모두 맞아야 한다. (1) 자리: 명중이 지수 최상위 비트(bit 30)에 떨어질 확률은 $1/32$이다. 학습된 가중치는 모두 $|w| < 2$이므로 그 비트는 항상 0이어서 뒤집히면 반드시 $0 \to 1$, 즉 10^{38}배가 된다(예 1). (2) 부호: 뒤집힌 가중치가 $+10^{38}$이면 다음 층을 지배하지만, -10^{38}이면 ReLU가 0으로 잘라 대개 무해하다. 그래서 양수 가중치 비율 π_+가 곱해진다. (3) 경로: 그 가중치가 실제로 출력에 이르는 경로에 있어야 한다. 입력이 항상 0인 픽셀에 연결된 가중치나 죽은 뉴런의 가중치는 아무리 커져도 출력에 닿지 않는다. 이 확률을 α라 한다. 세 사건이 독립이면 $q = \frac{1}{32}\pi_+\alpha$이다. 예컨대 `mnist_linear`는 $\pi_+ = 0.49$이고 맞춘 $\alpha = 0.56$이므로 $q \approx 0.0086$, 즉 명중 약 120개에 하나꼴로 치명적이다.

모델 B (누적 손상 모형, 모든 방어). 클리핑처럼 치명 명중을 없애는 방어에서는 손상이 서서히 쌓인다. 이를 로그-로지스틱 생존 곡선

$$S(k) = \frac{1}{1 + (k/k_{50})^{\beta}} \tag{5}$$

으로 요약한다. k_{50}은 생존률 50 %의 명중 수, β는 기울기이다. 방어 d의 이득을 같은 생존률을 주는 선량의 배수 $G_d = k_{50}^{(d)}/k_{50}^{(\text{없음})}$로 정의하면, 방어 d를 켠 모델의 생존 시간은 $T_{50}^{(d)} = G_d\,T_{50}$이다.

모델 A는 다음 명제로 정당화된다.

명제 1 (치명 명중의 솎아내기). 명중 수 K가 평균 λ인 푸아송 분포를 따르고, 각 명중이 다른 명중과 독립적으로 확률 q로 치명적이라 하자. 그러면 치명 명중 수는 평균 $q\lambda$인 푸아송 분포를 따르고, 치명 명중이 없을 확률은 정확히 $e^{-q\lambda}$이다. stress 모드처럼 $K \sim \mathrm{Bin}(N_w, p)$이면 그 확률은 $(1-pq)^{N_w}$이며, $pq \ll 1$일 때 e^{-qpN_w}와 같다.

증명. 푸아송 과정의 독립 솎아내기(thinning) 성질이다. $K = k$가 주어졌을 때 치명 명중 수는 $\mathrm{Bin}(k, q)$이므로 $P(\text{치명 없음}) = \sum_k e^{-\lambda}\lambda^k/k!\,(1-q)^k = e^{-\lambda}e^{\lambda(1-q)} = e^{-q\lambda}$. 이항의 경우 각 가중치가 독립적으로 "명중하고 치명"일 확률이 pq이므로 $(1-pq)^{N_w}$. □

따라서 모델 A는 근사가 아니라 "명중이 서로 독립이고 치명 여부도 독립"이라는 가정 아래의 정확한 결과이며, 실험이 검증하는 것은 그 가정과 식 (4)의 분해이다. 같은 논법으로 중복 방어의 한계도 유도된다.

명제 2 (TMR의 한계). 세 복제본이 각각 k번($k \ll N_w$) 독립적으로 명중되고 가중치마다 세 복제본의 중앙값을 취하면, TMR 출력에 치명 가중치가 생길 기대 수는 근사적으로 $3k^2q/(32N_w)$이고, 생존률은 $S_{\mathrm{TMR}}(k) \approx \exp\big(-3k^2q/(32N_w)\big)$, 따라서

$$k_{50}^{\mathrm{TMR}} \approx \sqrt{\frac{32\,N_w \ln 2}{3\,q}}. \tag{6}$$

증명 개요. 한 가중치가 세 복제본 중 둘 이상에서 명중될 확률은 $\approx 3(k/N_w)^2$이므로 그런 가중치는 평균 $3k^2/N_w$개이다. 두 명중의 중앙값이 치명적이려면 둘 다 지수 최상위 비트를 뒤집어야 하고(확률 $1/32^2$) 그 가중치가 양수·활성이어야 하므로(확률 $\pi_+\alpha = 32q$) 가중치당 치명 확률은 $32q/1024 = q/32$이다. 곱하면 기대 치명 수 $3k^2q/(32N_w)$이고, 명제 1의 논법으로 생존률은 그 지수함수이다. □

식 (6)은 TMR의 이득이 N_w의 제곱근으로 커진다는 뜻이다. 비슷하게 복제본 n개의 로짓 평균은 복제본 하나라도 치명 명중을 받으면 무너지므로 $S_{\mathrm{mean}} = S^n$, 즉 이득 $G = 1/n$이 예측된다.

두 모형의 파라미터는 stress 모드 데이터(각 조건의 생존 횟수/시행 수)에 이항 최대가능도로 맞춘다. 검증은 네 가지다. (i) 맞추지 않은 E3(궤도 모드) 데이터에서 예측 생존률과 실측 생존률의 차이, (ii) 모델 A의 q가 모델마다 같다는 귀무가설의 가능도비 검정(H4), (iii) E2(단일 명중)에서 비트별 생존률이 q의 분해와 맞는지, (iv) 식 (6)의 TMR 한계가 고선량 E5와 맞는지. 생존률의 신뢰구간은 Clopper–Pearson 95 % 구간을 쓴다.

4 결과

4.1 p에 따른 정확도와 생존률 (H1, H2)

그림 2와 표 2에 결과를 정리하였다. 방어가 없을 때 정확도 중앙값은 $p \le 0.01\,\%$(기대 명중 약 12개)까지 무손상 수준(96.6 %)을 유지하다가, $p = 0.03\,\%$(명중 약 31개)에서 생존률이 0.6로 떨어지기 시작하고, $p = 0.1\,\%$에서 중앙값 67.4 %, $p = 0.3\,\%$에서 40.9 %(생존률 0.0), $p \ge 1\,\%$에서는 찍기 수준에 가까운 15.4 %로 무너진다. 즉 H1은 지지되며, 감소는 $\log p$에 대해 $0.03\,\% \sim 0.5\,\%$ 사이의 약 한 자릿수 구간에 집중되어 있어 H2(임계 구간의 존재)도 지지된다.

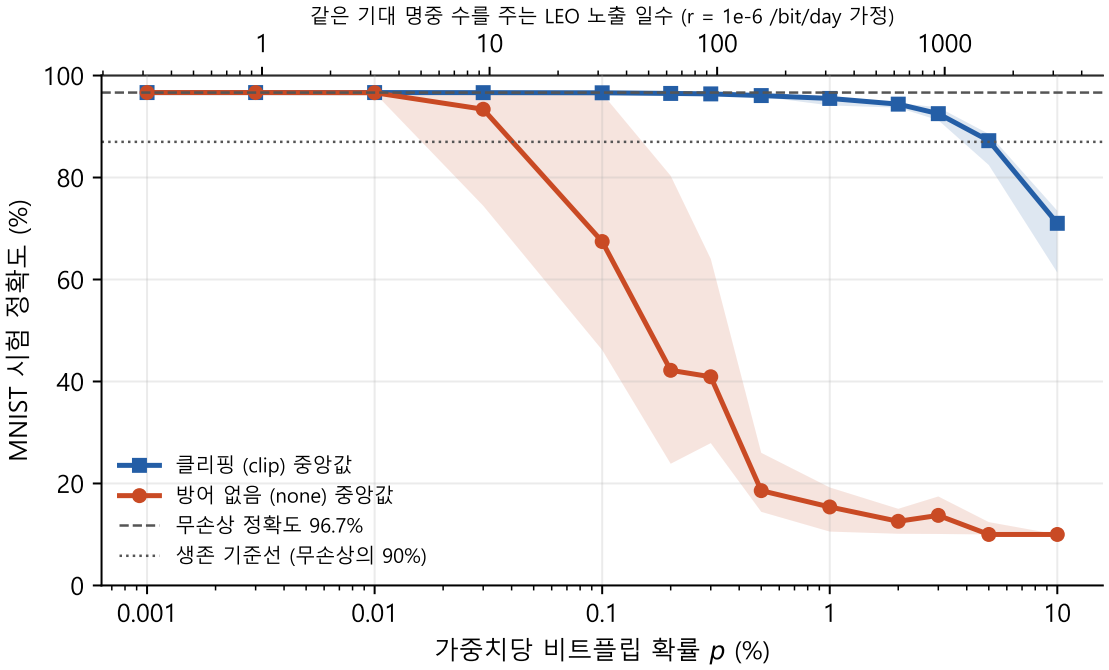


그림 **2.** E1: p에 따른 정확도. 선은 10회 시행의 중앙값, 띠는 사분위범위(IQR)이다. 위쪽 축은 식 (2)로 환산한 LEO 노출 일수이다.

표 **2.** E1 조건별 요약(각 10회). $\bar{k}$는 평균 명중 수, LEO 일수는 식 (2)($r = 10^{-6}$/bit/day). 생존률은 정확도가 무손상의 90 % 이상인 시행의 비율, 붕괴율은 NaN/∞가 발생한 시행의 비율.

p (%)	$\bar{k}$	LEO 일수	방어 없음				클리핑			
			중앙값	IQR	생존률	붕괴율	중앙값	IQR	생존률	붕괴율
0.001	1	0.3	96.7	96.7–96.7	1.0	0.0	96.7	96.7–96.7	1.0	0.0
0.003	4	0.9	96.7	96.7–96.7	1.0	0.0	96.7	96.7–96.7	1.0	0.0
0.01	12	3.1	96.6	96.6–96.7	1.0	0.0	96.7	96.7–96.7	1.0	0.0
0.03	31	9.4	93.4	74.5–96.6	0.6	0.0	96.6	96.6–96.7	1.0	0.0
0.1	104	31.3	67.4	46.2–96.5	0.4	0.0	96.6	96.5–96.7	1.0	0.0
0.2	208	62.5	42.2	23.9–80.3	0.1	0.1	96.5	96.0–96.6	1.0	0.0
0.3	308	93.8	40.9	27.9–64.0	0.0	0.0	96.4	96.3–96.6	1.0	0.0
0.5	511	156.2	18.6	14.4–26.0	0.1	0.1	96.1	95.9–96.4	1.0	0.0
1	1,019	312.5	15.4	10.6–19.2	0.0	0.2	95.5	94.1–95.9	0.9	0.0
2	2,031	625.0	12.6	10.1–15.0	0.0	0.2	94.4	93.7–94.6	1.0	0.0
3	3,060	937.5	13.7	10.1–17.5	0.0	0.2	92.5	91.2–93.8	0.9	0.0
5	5,080	1,562.5	10.0	10.0–12.4	0.0	0.5	87.2	82.4–88.5	0.6	0.0
10	10,178	3,125.0	10.0	10.0–10.0	0.0	0.9	71.0	61.4–73.5	0.0	0.0

4.2 같은 선량, 다른 운명: 이봉 분포 (Q2)

그림 3는 시행 하나하나를 점으로 찍은 것이다. 방어 없음의 $p = 0.03\,\% \sim 0.3\,\%$ 구간에서는 같은 p라도 무손상에 가까운 시행(96 %대)과 크게 손상된 시행(26.8 %까지)이 공존하며, 그 사이가 비어 있다. 예컨대 $p = 0.1\,\%$의 10회 시행 중 4회는 96 % 이상, 나머지 6회는 33–78 %였다. 이 구간에서 명중 수 k는 시행 간에 거의 같으므로(표 2의 $\bar{k}$ 참조), 차이는 명중 개수가 아니라 어느 가중치의 어느 비트가 맞았는가에서 온다.

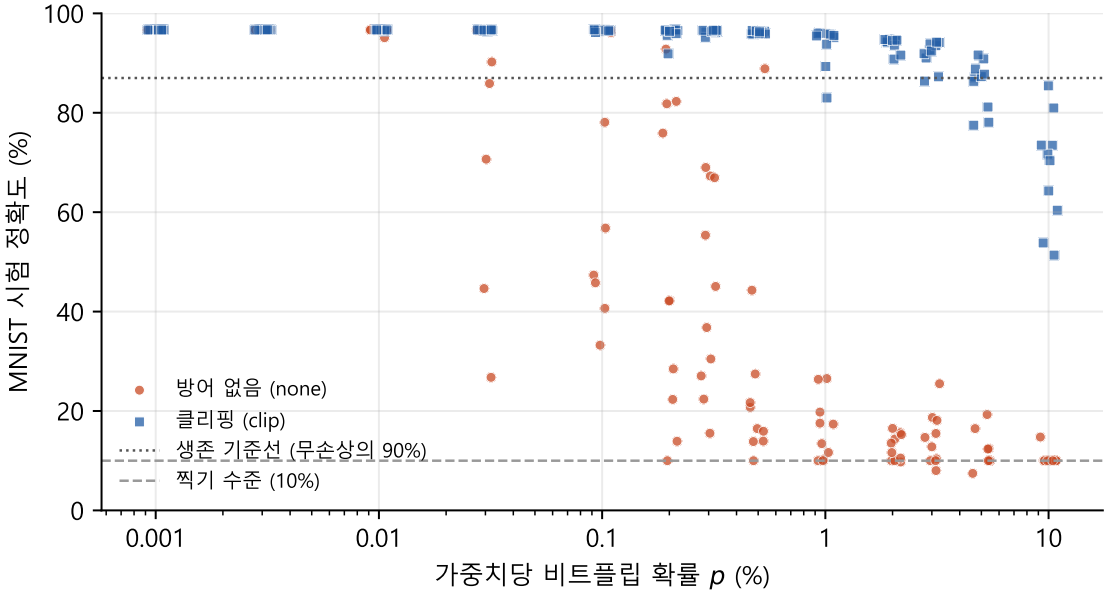


그림 **3.** E1의 모든 시행(점 하나 = 시행 1회, 가로 위치는 겹침을 피하기 위해 약간 흔듦). 방어 없음은 중간 선량대에서 두 무리로 갈라진다.

그림 4은 이 전이 구간의 시행들을 히스토그램으로 모은 것이다. 방어 없음의 분포는 무손상 정확도 근처의 뾰족한 봉우리와 10–80 %에 넓게 퍼진 손상 무리로 나뉘고 그 사이(85–93 %)는 거의 비어 있다. 네 모델을 무손상 대비 정확도로 합산해도 같은 모양이다. 같은 선량의 클리핑 시행은 모두 무손상 봉우리에 모여 있다.

> **노트 6** (왜 두 봉우리인가, 왜 평균이 아닌가). 두 봉우리는 "치명 명중이 있었는가 없었는가"라는 두 갈래 사건의 흔적이다. 명중 k개 가운데 bit 30 명중이 하나도 없을 확률은 $(31/32)^k$로, $k = 31$이면 약 37 %, $k = 104$이면 약 4 %이다. 없으면 정확도는 무손상 근처에 머물고, 하나라도 있으면(그리고 그 가중치가 양수·활성이면) 한 층의 출력 전체가 10^{38}에 지배되어 크게 떨어진다. 중간값은 두 사건의 어느 쪽에서도 나오지 않으므로 그 사이가 비는 것이다. 이런 분포를 평균±표준편차로 요약하면 "아무도 겪지 않은" 중간값을 보고하게 된다. 실제로 $p = 0.03\,\%$의 평균은 80.1 %지만 중앙값은 93.4 %이며, 10회 중 몇 회가 봉우리에 남았는가(생존률)가 분포를 가장 잘 요약한다.

4.3 붕괴(NaN/∞)의 출현

붕괴는 방어 없음에서 $p = 0.2\,\%$부터 나타나 $p = 1\,\%$에서 0.2, $p = 5\,\%$에서 0.5, $p = 10\,\%$에서 0.9로 증가한다(그림 5b). 전체 시행에서 명중 비트 중 지수부의 비율은 25.0 %, 부호 비트는 3.1 %로 무작위 기대값(8/32, 1/32)과 일치한다. 그러나 붕괴와 큰 손상은 모두 지수부 명중, 특히 bit 30 명중이 $\pm\infty$ 또는 10^{38} 크기의 가중치를 만들 때 발생한다(4.9절의 비트별 실험 참조). 클리핑 조건에서는 260회 중 붕괴가 한 번도 없었다.

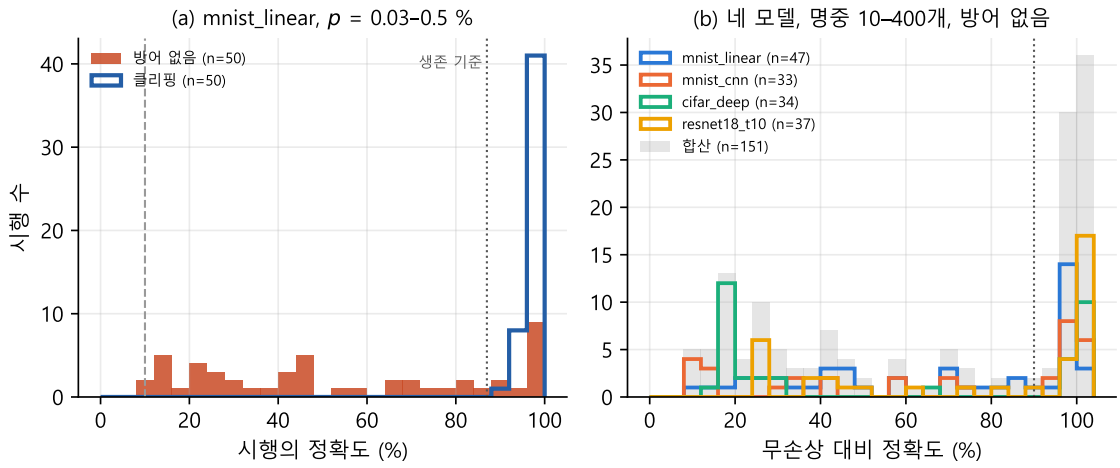


그림 **4.** 이봉 분포. (a) `mnist_linear`의 $p = 0.03$–$0.5\,\%$ 구간 50회 시행의 정확도 분포: 방어 없음(채움)과 클리핑(선). (b) 네 모델의 명중 10–400개 구간 151회 시행을 무손상 대비 정확도로 합산(회색)하고 모델별로 겹쳐 그린 것.

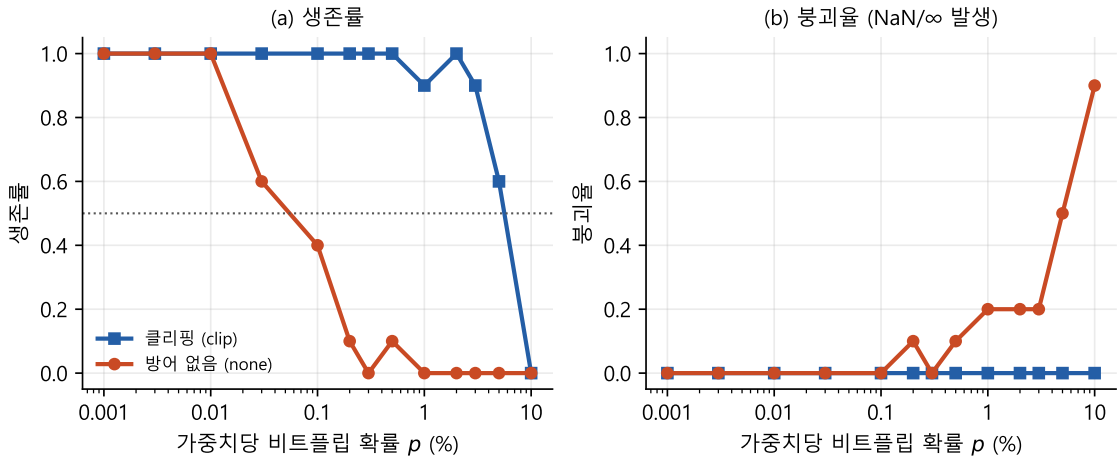


그림 **5.** (a) 생존률과 (b) 붕괴율. 점선은 생존률 50 %.

4.4 클리핑의 효과 (H3)

클리핑은 생존률 1.0을 $p = 0.5\,\%$까지 유지하고, $p = 1\,\%$에서도 중앙값 95.5 %(방어 없음 15.4 %), $p = 5\,\%$에서 87.2 %(방어 없음 10.0 %)를 기록하였다. 생존률이 50 %를 가로지르는 확률을 $\log p$ 선형 보간으로 구하면 방어 없음 $p_{50} \approx 0.055\,\%$, 클리핑 $p_{50} \approx 5.61\,\%$로, 클리핑은 견딜 수 있는 선량을 약 102배 높였다. 클리핑도 $p = 10\,\%$(가중치 열 개 중 하나가 손상)에서는 중앙값 71.0 %로 떨어지는데, 이때의 손상은 ∞가 아니라 잘려서 ± 3이 된 수천 개의 가중치가 누적된 결과이다. 따라서 H3은 지지되며, 그 한계도 함께 드러났다.

4.5 LEO 노출 일수로의 환산

식 (2)에 따르면, $r = 10^{-6}$/bit/day(Alsat-1 측정값 [13]) 아래 E1의 모델 `mnist_linear`($N_{\text{bits}} = 3,252,224$)는 하루에 약 3.25개의 비트플립을 받는다. JASON-2 측정값(4.8×10^{-7})을 쓰면 일수는 약 2배로 늘어난다. 생존률 50 %에 해당하는 선량은 방어 없음에서 약 17일, 클리핑에서 약 1754일이다. 즉 방어 없는 float32 신경망은 수 주 안에 절반의 확률로 10 % 이상의 성능 손실을 겪지만, 가장 단순한 클리핑만으로도 수 년 규모로 늘어난다. 이 수치는 r에 정비례하므로, 궤도·태양 활동·소자에 따라 r이 10배 달라지면 일수도 10배 달라진다.

4.6 모델 크기 축 (E1-M): 생존을 결정하는 것은 확률이 아니라 명중 수

같은 실험을 표 1의 세 모델에 반복하였다(p 9단계, 큰 모델은 10^{-6}부터, 각 10회). 그림 6(a)(c)에서 보듯 p를 가로축으로 두면 큰 모델일수록 곡선이 왼쪽으로 이동한다. 즉 같은 p에서는 큰 모델이 먼저 무너지며(H5), "큰 모델이 더 강건하다"는 통념은 성립하지 않는다. 방어 없음의 생존률 50 % 지점은 `mnist_linear` $p_{50} = 0.0548\,\%$에서 `resnet18_t10` $p_{50} = 0.001\,\%$로 약 50배 낮아진다. 그러나 가로축을 평균 명중 수 $\bar{k} = pN_w$로 바꾸면(그림 7) 네 모델의 생존률 곡선이 거의 한 곡선으로 겹친다. 생존률 50 %에 해당하는 명중 수 k_{50}은 56, 66, 64, 112개로, 가중치 수가 110배 차이 나는 모델 사이에서 2배 안에 든다(표 3). 즉 방어 없는 float32 모델의 생존은 "몇 개의 비트가 뒤집혔는가"로 결정되며, 수십 개의 무작위 명중 가운데 지수 최상위 비트의 0 → 1 플립이 하나라도 섞이면 무너진다는 4.9절의 설명과 맞는다.

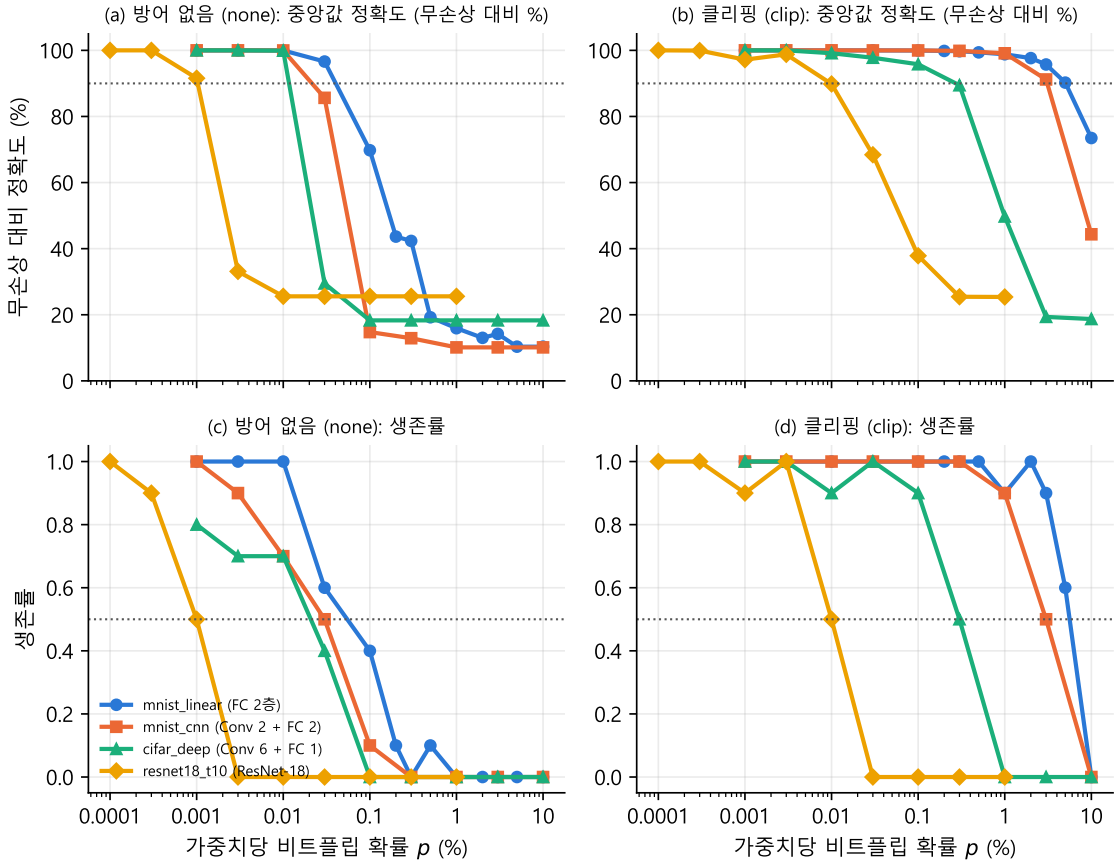


그림 **6.** E1-M: 네 모델의 p에 따른 정확도. (a)(b) 무손상 대비 중앙값 정확도, (c)(d) 생존률. 왼쪽 열은 방어 없음, 오른쪽 열은 클리핑.

표 **3.** E1-M 모델별 요약. 명중/일은 rN_{bits}($r = 10^{-6}$/bit/day), $p_{50} \cdot k_{50}$은 생존률이 50 %를 가로지르는 확률과 그때의 기대 명중 수($\log p$ 선형 보간), LEO 일수는 식 (2).

모델	N_w	N_{bits}	무손상 정확도	명중/일 (r=10^{-6})	방어 없음, 생존률 50%			클리핑, 생존률 50%	
					p_{50} (%)	k_{50}	LEO 일수	p_{50} (%)	LEO 일수
`mnist_linear`	101,632	3,252,224	96.7	3.3	0.0548	56	17일	5.6	1,754일
`mnist_cnn`	220,064	7,042,048	98.7	7.0	0.03	66	9일	3	937일
`cifar_deep`	307,040	9,825,280	54.6	9.8	0.0208	64	7일	0.3	94일
`resnet18_t10`	11,172,032	357,505,024	39.1	357.5	0.001	112	7.5시간	0.01	3일

이 결과는 LEO 노출 시간의 해석을 바꾼다. 하루 명중 수는 rN_{bits}로 모델 크기에 비례하므로, 생존률 50 %까지의 시간은 $T_{50} \approx k_{50}/(rN_{\text{bits}})$, 즉 모델 크기에 반비례한다. 표 3에서 방어 없음의 T_{50}은 `mnist_linear`의 17일에서 `resnet18_t10`의 7.5시간으로 줄어든다. $k_{50} \approx 60$–110을 그대로

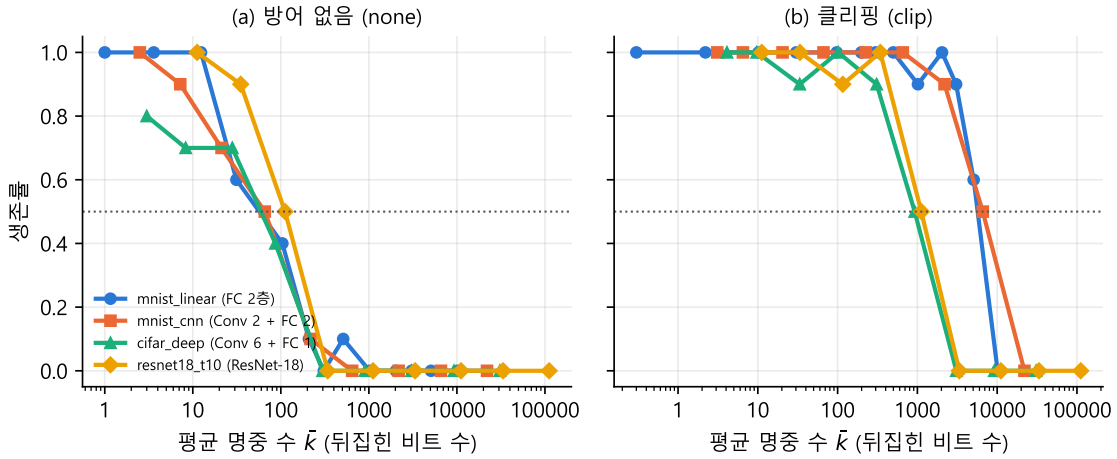


그림 **7.** 가로축을 평균 명중 수 $\bar{k}$로 바꾼 생존률. 방어 없음(a)에서는 네 모델이 한 곡선으로 모인다.

적용하면 ResNet-50(2,560만 파라미터)은 2.0시간, 1억 파라미터급 모델은 31분 안팎이다(4.10절의 모형으로 계산). 방어 없는 float32 탑재 신경망은 궤도에서 하루를 버티지 못한다는 뜻이다.

클리핑의 이득은 과제의 여유에 따라 달랐다. p_{50}의 비(클리핑/방어 없음)는 MNIST 두 모델에서 약 102배와 100배였으나, 무손상 정확도가 낮은 CIFAR-10 두 모델에서는 14배와 10배에 그쳤다. 클리핑은 ∞/NaN 붕괴는 완전히 막지만(네 모델 모두 클리핑 조건에서 붕괴 0), ± 3으로 잘린 수백 개의 가중치가 남기는 누적 손상은 막지 못하며, 클래스 간 여유가 작은 모델은 그 손상에 더 민감하다. 그림 7(b)에서 클리핑 조건의 곡선은 방어 없음과 달리 모델별로 갈라지는데, 이것이 그 증거다.

4.7 궤도 모드 (E3): SAA에 몰려 들어오는 명중

`leo_saa` 모드에서는 하루 명중의 90 %가 세 번의 SAA 통과(각 12분)에 몰려 들어온다. 표 4와 그림 8에서 보듯 결과는 stress 모드와 같은 명중 수에서 같은 생존률을 보였다. 방어 없는 `mnist_linear`는 7일까지 생존률 0.9–1.0을 유지하다가 30일에 0.3, 90일에 0.1로 떨어졌고, `mnist_cnn`은 14일에 0.3, 60일에 0이었다. 클리핑은 90일(명중 약 300–630개)까지 생존률 1.0이었다. 추론 시점에 명중이 시간적으로 몰려 있는지 여부는 결과에 영향을 주지 않았는데, 이는 추론 중 가중치가 갱신되지 않아 명중의 순서가 무의미하기 때문이다.

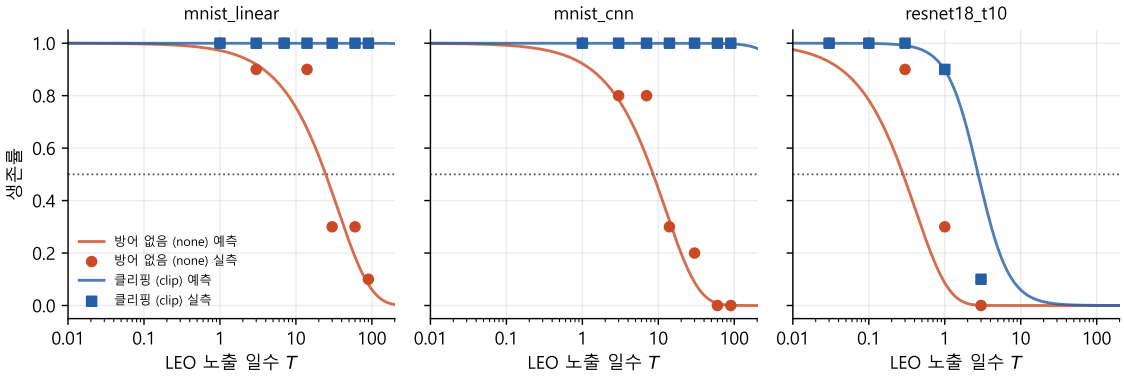


그림 **8.** E3: 궤도 모드(`leo_saa`) 실측 생존률(점)과 stress 모드로 맞춘 수학 모델의 예측(선). 모델은 E3 데이터를 보지 않았다.

표 **4.** E3 궤도 모드 실측 생존률과 모델 예측(식 (3), (5), stress 데이터로만 맞춤). 예측은 각 조건에 실제로 전달된 평균 명중 수 $\bar{k}$를 넣어 계산하였다. 전체 38개 조건에서 평균 절대 오차 0.06, 최대 0.38.

모델	T (일)	방어 없음			클리핑		
		$\bar{k}$	실측	예측	$\bar{k}$	실측	예측
`mnist_linear`	1	4	1.0	0.97	4	1.0	1.00
`mnist_linear`	3	10	0.9	0.92	11	1.0	1.00
`mnist_linear`	7	23	1.0	0.82	24	1.0	1.00
`mnist_linear`	14	48	0.9	0.66	51	1.0	1.00
`mnist_linear`	30	98	0.3	0.43	98	1.0	1.00
`mnist_linear`	60	195	0.3	0.18	200	1.0	1.00
`mnist_linear`	90	287	0.1	0.08	298	1.0	1.00
`mnist_cnn`	1	7	1.0	0.92	6	1.0	1.00
`mnist_cnn`	3	20	0.8	0.79	18	1.0	1.00
`mnist_cnn`	7	48	0.8	0.58	46	1.0	1.00
`mnist_cnn`	14	100	0.3	0.32	98	1.0	1.00
`mnist_cnn`	30	217	0.2	0.08	210	1.0	1.00
`mnist_cnn`	60	439	0.0	0.01	413	1.0	1.00
`mnist_cnn`	90	646	0.0	0.00	632	1.0	1.00
`resnet18_t10`	0.03	1	1.0	0.99	1	1.0	1.00
`resnet18_t10`	0.1	3	1.0	0.98	57	1.0	1.00
`resnet18_t10`	0.3	95	0.9	0.52	102	1.0	0.99
`resnet18_t10`	1	364	0.3	0.08	354	0.9	0.90
`resnet18_t10`	3	1,072	0.0	0.00	1,054	0.1	0.46

4.8 방어 비교 (E5): 무엇이 얼마나 늘려 주는가

그림 9와 표 6는 `mnist_linear`에서 방어 6종을 비교한 것이다. 패리티와 TMR은 실험한 최대 선량($p = 3\,\%$, 명중 약 3,000개)까지 생존률 1.0, 중앙값 정확도 96.3 % 이상이었다. 패리티는 1비트 오류를 전부 검출해 해당 가중치를 0으로 되돌리므로 손상이 "가중치 3 %를 0으로 만든 것"에 그치고, TMR은 같은 가중치가 세 복제본 중 둘 이상에서 맞을 때만 손상되므로 $k \ll N_w$에서는 사실상 무손상이다. 클리핑의 이득은 모델 B로 맞춘 k_{50}의 비로 약 83.8배였다(표 2의 보간값 102배와 같은 자릿수). 로짓 중앙값 앙상블은 $p = 0.1\,\%$까지 생존률 0.8을 유지했지만 0.3 %에서 0으로 떨어져 이득이 1.8배에 그쳤고, 로짓 평균 앙상블은 이득 0.2배로 방어 없음보다 나빴다. 평균은 복제본 다섯 개 중 하나라도 10^{38} 크기의 로짓을 내면 그에 지배되는데, 복제본이 다섯이므로 그런 복제본이 생길 확률도 다섯 배이기 때문이다. 중앙값이 평균보다 이상치에 강하다는 통계의 기본 사실이 방어 설계에서 그대로 드러난다. 실측 이득 0.2배는 3.5절의 예측 $G = 1/5 = 0.2$와 일치한다. 실제로 평균 앙상블의 생존률은 복제본 다섯이 합쳐 명중 약 14개를 받는 $p = 0.003\,\%$에서 이미 0.7로 떨어지기 시작하였다.

패리티와 TMR의 한계를 보기 위해 p를 50 %까지 올린 결과가 표 5이다. TMR은 $p = 10\,\%$에서 생존률 0.8, 20 %에서 0으로 무너졌다. 식 (6)에 `mnist_linear`의 q를 넣으면 $k_{50}^{\mathrm{TMR}} \approx 9,327$(즉 $p \approx 9\,\%$)로, 모델 B로 실측에 맞춘 k_{50}(표 6의 10,639)과 15 % 안에서 맞는다. 즉 TMR의 이득은 이득 상수가 아니라 $\sqrt{N_w/q}$에 비례하는 양이며, 가중치가 많은 모델일수록 TMR이 상대적으로 더 유리하다. 패리티는 가중치의 20 %가 0이 되어도 생존률 1.0, 30 %에서 0.8(중앙값 88.3 %)로, 가장 강건한 동시에 가장 싼 방어였다(메모리 $+1/32$).

4.9 비트별 치명도 (E2): 32비트 중 하나만 위험하다

정확히 한 비트만 한 번 뒤집는 실험(E2)으로 식 (4)의 분해를 직접 검증하였다. 부호 비트(31), 지수 비트 8개(30–23), 가수 비트 4개(22, 16, 10, 0)를 각각 `mnist_linear`는 50회, 나머지 세 모델은 30회 뒤집었다. 그림 10와 표 7의 결과는 단순하다. **bit 30을 제외한 모든 비트에서 생존률은 1.00이었다.** 부호 반전은 가중치 하나의 부호를 바꿀 뿐이고, bit 29–23은 학습된 가중치($|w| < 1$, $E \le 126$)에서 대부분 이미 1이어서 $1 \to 0$ 플립이 값을 줄이며, 0인 비트(bit 25, 23 등)가 $0 \to 1$로 바뀌어도 값은 2–16배 커지는 데 그쳐 수만 개 가중치의 합에 묻힌다. 오직 bit 30의 $0 \to 1$ 플립만이 2^{128}배라는 규모로 가중치 하나를 네트워크 전체 위에 올려놓는다.

bit 30 단일 명중의 생존률은 `mnist_linear` 0.74 [0.60, 0.85], `mnist_cnn` 0.70 [0.51, 0.85],

표 5. 고선량에서의 TMR과 패리티(`mnist_linear`, 각 10회). TMR 예측은 식 (6)의 $\exp(-3k^2q/(32N_w))$.

p (%)	$\bar{k}$	k/N_w	TMR 실측	TMR 예측	패리티 실측	패리티 중앙값
0.001	1	0.00	1.0	1.00	1.0	96.7
0.003	3	0.00	1.0	1.00	1.0	96.7
0.01	10	0.00	1.0	1.00	1.0	96.7
0.03	30	0.00	1.0	1.00	1.0	96.7
0.1	102	0.00	1.0	1.00	1.0	96.7
0.3	306	0.00	1.0	1.00	1.0	96.6
1	1,021	0.01	1.0	0.99	1.0	96.6
3	3,061	0.03	1.0	0.93	1.0	96.3
5	5,108	0.05	1.0	0.81	1.0	96.1
10	10,188	0.10	0.8	0.44	1.0	95.3
20	20,331	0.20	0.0	0.04	1.0	92.3
30	30,501	0.30	0.0	0.00	0.8	88.3
50	50,842	0.50	0.0	0.00	0.0	74.2

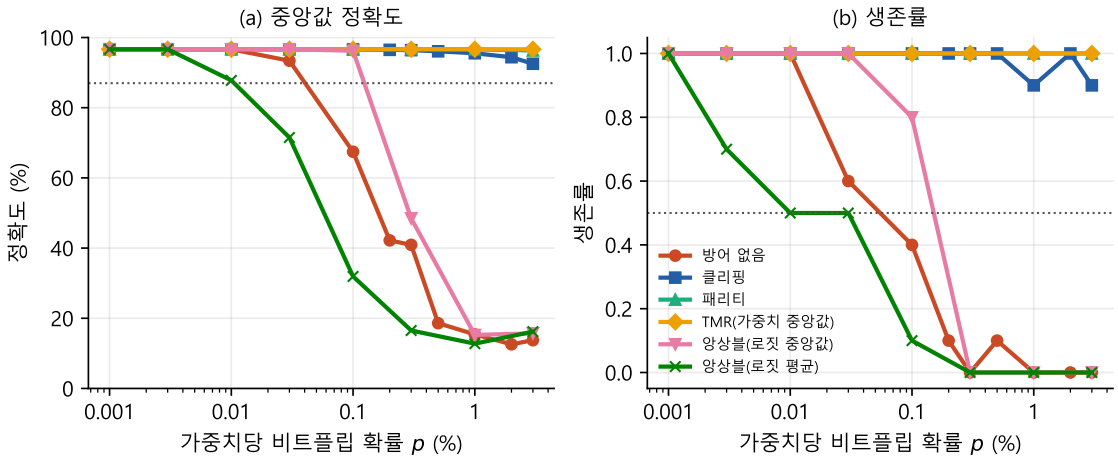


그림 **9.** E5: `mnist_linear`의 방어 6종. (a) 중앙값 정확도, (b) 생존률. 패리티와 TMR은 겹쳐서 TMR 아래에 있다.

표 6. E5 방어별 중앙값 정확도(괄호는 생존률)와 모델 B로 맞춘 k_{50}, 이득 G_d. “>”는 실험 범위 안에서 생존률이 50 % 아래로 내려가지 않았음을 뜻한다.

방어	p=0.001%	p=0.003%	p=0.01%	p=0.03%	p=0.1%	p=0.3%	p=1%	p=3%	k_{50}	이득
없음	96.7 (1.0)	96.7 (1.0)	96.6 (1.0)	93.4 (0.6)	67.4 (0.4)	40.9 (0.0)	15.4 (0.0)	13.7 (0.0)	62	1.0
클리핑	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.6 (1.0)	96.6 (1.0)	96.4 (1.0)	95.5 (0.9)	92.5 (0.9)	5,155	83.8
패리티	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.6 (1.0)	96.6 (1.0)	96.3 (1.0)	31,371	509.7
TMR	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	10,639	172.8
앙상블(중앙값)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.7 (1.0)	96.2 (0.8)	48.5 (0.0)	15.3 (0.0)	15.7 (0.0)	109	1.8
앙상블(평균)	96.7 (1.0)	96.7 (0.7)	87.8 (0.5)	71.5 (0.5)	31.9 (0.1)	16.5 (0.0)	12.8 (0.0)	16.2 (0.0)	13	0.2

`cifar_deep` 0.53 [0.34, 0.72], `resnet18_t10` 0.83 [0.65, 0.94]였다. 모델 A에서 bit 30 명중 하나의 생존률은 $1-\pi_+\alpha = 1-32q$이므로, E1로 맞춘 q가 예측하는 값은 각각 0.72, 0.63, 0.48, 0.78이다. 네 모델 모두 예측이 신뢰구간 안에 들었다. 거꾸로 E2에서 독립적으로 $q_{E2} = \frac{1}{32}\sum_b (1-S_b)$를 구하면 0.0081, 0.0094, 0.0146, 0.0052으로 E1 적합값(0.0086, 0.0115, 0.0163, 0.0068)과 맞는다. 즉 수십 개의 무작위 명중에서 본 붕괴율과 단 한 비트의 치명도는 같은 수 q로 연결되며, 그 수는 “bit 30이 뽑힐 확률 $1/32$ × 양수 가중치 × 활성 경로”로 설명된다. 클리핑 조건에서는 bit 30을 포함한 모든 비트에서 생존률 1.00이었다. 뒤집힌 가중치 하나가 ± 3으로 잘리는 것은 무해하기 때문이다.

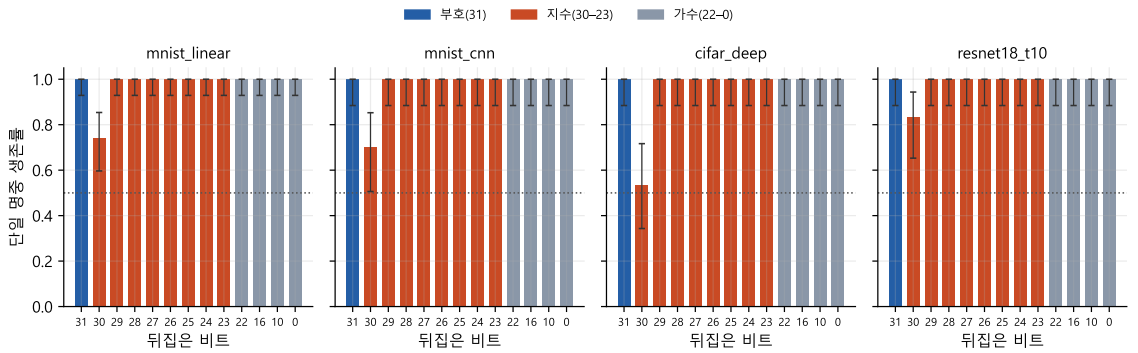


그림 **10.** E2 비트 지도: 비트 하나를 정확히 한 번 뒤집었을 때의 생존률(방어 없음)과 Clopper–Pearson 95 % 신뢰구간. 32비트 가운데 bit 30만 치명적이다.

표 **7.** E2 비트별 단일 명중 생존률 [95 % 신뢰구간]. 아래 세 줄은 E2에서 독립 추정한 q_{E2}, E1 적합 q, 그리고 bit 30 생존률의 예측$(1-32q)$과 실측.

비트	`mnist_linear`	`mnist_cnn`	`cifar_deep`	`resnet18_t10`	`mnist_linear` 클리핑
31 (부호)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
30 (지수 MSB)	0.74 [0.60, 0.85]	0.70 [0.51, 0.85]	0.53 [0.34, 0.72]	0.83 [0.65, 0.94]	1.00
29 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
28 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
27 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
26 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
25 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
24 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
23 (지수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
22 (가수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
16 (가수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
10 (가수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
0 (가수)	1.00 [0.93, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00 [0.88, 1.00]	1.00
$q_{E2} = \frac{1}{32}\sum_b (1-S_b)$	0.0081	0.0094	0.0146	0.0052	
q (E1 적합)	0.0086	0.0115	0.0163	0.0068	
bit 30 예측 $1-32q$ / 실측	0.72 / 0.74	0.63 / 0.70	0.48 / 0.53	0.78 / 0.83	

4.10 수학적 모델의 적합과 예측

표 8과 그림 11에 두 모형의 적합 결과를 정리하였다. 모델 A의 치명 확률 q는 네 모델에서 0.0068–0.0163(중앙값 0.0101)로, 가중치 수가 110배 다른 모델 사이에서 2.4배 안에 들었다(H4 지지). 식 (4)로 분해한 유효 전파 비율 α는 0.48–1.24였다. MNIST 모델의 $\alpha \approx 0.5$–0.8은 "입력의 15 %는 항상 0인 픽셀이고 각 픽셀이 평균 19 %의 이미지에서만 0이 아니다"라는 사실과 맞으며, CIFAR-10처럼 모든 픽셀이 값을 갖는 입력에서는 α가 1에 가깝다. 즉 q는 "1/32에 양수 비율과 입력의 밀도를 곱한 값"으로 거의 예측된다. 모델 A의 생존률 예측 오차(평균 절대 오차)는 stress 데이터에서 0.02–0.06이었다. "네 모델의 q가 같다"는 귀무가설을 가능도비로 검정하면 $D = 6.0$, 자유도 3, $p = 0.110$로 5 % 수준에서 기각되지 않으며, 공통 $q = 0.0100$이다. 즉 데이터는 "치명 확률은 모델 크기와 구조에 무관하다"(H4)와 양립한다.

표 **8.** 적합된 파라미터. $k_{50}^{A} = \ln 2/q$, MAE는 stress 데이터에서의 생존률 평균 절대 오차, T_{50} 예측은 $r = 10^{-6}$/bit/day.

모델	방어	π_+	q	α	k_{50}^{A}	k_{50}^{B}	β	MAE	T_{50} 예측
`mnist_linear`	없음	0.49	0.0086	0.56	80	62	1.7	0.04	25일
	클리핑					5,155	3.2	0.03	1,585일
`mnist_cnn`	없음	0.47	0.0115	0.78	60	48	1.4	0.02	9일
	클리핑					5,994	2.7	0.01	851일
`cifar_deep`	없음	0.42	0.0163	1.24	42	30	1.0	0.06	4일
	클리핑					758	1.7	0.04	77일
`resnet18_t10`	없음	0.46	0.0068	0.48	101	99	2.7	0.04	6.8시간
	클리핑					985	2.1	0.04	3일

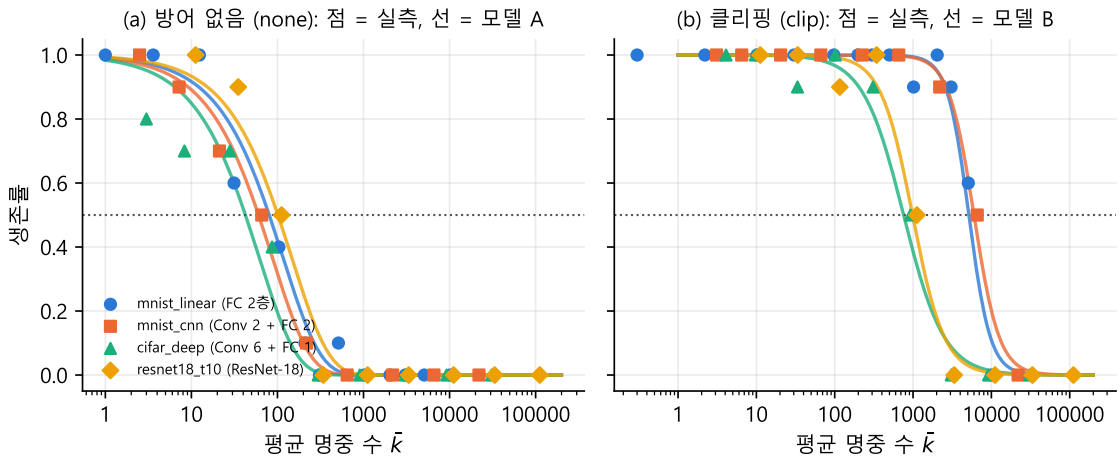


그림 **11.** 실측 생존률(점)과 적합된 모델. (a) 방어 없음은 모델 A(e^{-qk}), (b) 클리핑은 모델 B(로그-로지스틱).

가장 중요한 검증은 E3이다. stress 데이터로만 맞춘 모델 A·B로 궤도 모드의 생존률을 예측하면, 38개 조건에서 평균 절대 오차 0.06, 최대 0.38이었다(표 4). 가장 큰 오차는 `resnet18_t10`의 $T = 0.3$일 방어 없음(예측 0.52, 실측 0.9)과 $T = 3$일 클리핑(예측 0.46, 실측 0.1)으로, 둘 다 생존률이 50 % 부근을 지나는 가장 가파른 구간이라 10회 시행의 이항 잡음(± 0.3)이 가장 큰 곳이다. 명중이 시간적으로 몰려 들어와도 식 (3)이 그대로 맞는다.

이제 이 모형으로 임의의 조합을 계산할 수 있다. 네 모델의 중앙값 $q = 0.0101$을 쓰면 ResNet-50(2,560만 파라미터)이 방어 없이 LEO에서 생존률 50 %에 이르는 시간은 2.0시간, 1억 파라미터 모델은 31분이다. 클리핑을 켜면 여유가 큰 과제에서 약 100배(수 년), 여유가 작은 과제에서 10–15배(수 일)로 늘어나고, 패리티나 TMR을 쓰면 실험 범위 안에서는 한계를 찾지 못했다. 반대로 요구 생존률 S^*와 임무 기간 T가 주어지면 허용 가능한 모델 크기 $N_{\text{bits}} \le -\ln S^*/(q\,r\,T)$를 바로 구할 수 있다.

5 논의

5.1 왜 “개수”가 아니라 “위치”인가

식 (1)에서 가수 비트는 값을 최대 2배 이내로만 바꾸지만 지수 비트는 2^{2^j} 배로 바꾼다. 신경망은 수천 개의 가중치가 합쳐지는 구조라 가수 비트 수십 개의 오류는 통계적으로 상쇄되지만, 지수 최상위 비트 하나는 10^{38} 크기의 항을 만들어 합 전체를 지배한다. 이 항은 증폭될 필요도 없이 배율 1로 전파되어(2.2절) 다음 층의 합과 출력층 전체를 지배한다. 중학교 수학으로 말하면, 평균은 이상치 하나에 끌려가지만 중앙값은 그렇지 않다는 사실이 TMR(중앙값)이 평균 앙상블보다 강건한 이유와 정확히 같다.

5.2 이봉 분포와 요약 통계의 선택

중간 선량대에서 결과가 두 무리로 갈라지는 현상은 “위험한 비트가 맞았는가”라는 베르누이 사건이 결과를 지배하기 때문이다. 명중 k개 중 bit 30 명중이 하나도 없을 확률은 $(31/32)^k$이며, $k = 31$이면 약 37 %, $k = 104$이면 약 4 %이다. 그러나 bit 30 명중이 있어도 해당 가중치의 지수 비트가 이미 1이었다면($|w| \ge 2$) 오히려 값이 작아져 피해가 없으므로, 실제 생존률은 이보다 높다. 이 구조에서는 평균이 “아무도 겪지 않은” 중간값을 보고하게 되므로, 신경망 내결함성 보고에서는 중앙값과 생존률을 함께 제시해야 한다.

5.3 선행 연구와의 비교

표 9에 본 연구와 비교 가능한 선행 연구의 수치를 모았다. 비트당 오류율(BER)로 보고된 결과와 비교할 때는 본 연구의 가중치당 확률 p를 $\mathrm{BER} = p/32$로 환산하였다.

표 9. 선행 연구와의 정량 비교. 본 연구의 값은 표 2과 4.9절에서 가져왔다.

연구	설정	보고된 결과	본 연구의 대응 결과
Hong 외 2019 [8]	float32, MNIST LeNet-5(62,598개) 등 8개 모델의 모든 비트를 전수 플립	파라미터의 45–51 %가 취약(정확도 10 % 이상 하락). 피해는 지수 최상위 비트의 $0 \to 1$ 플립이 거의 전부, $1 \to 0$ 플립은 피해 없음. ReLU-6로 취약 비율 1.4–2.4 %, 8비트 양자화로 0 %	취약 기준이 본 연구의 생존 기준(무손상의 90 %)과 같음. E2에서 bit 30 단일 플립의 "취약" 비율 $1 - S_{30}$은 `mnist_linear` 26 %, `cifar_deep` 47 %로, ReLU 모델에서 이 45–51 %와 같은 자릿수
Yan 외 2019 [19]	float32, ResNet-56/VGG16/NIN, 부호·지수 MSB·가수 MSB 각각	첫 층 지수 MSB 플립 최악 70 % 하락, 부호 비트 28 %, 가수 1 % 미만. MSB만 ECC/TMR 보호(파라미터당 0.24비트)로 28 %→0.27 %	지수부 선택 보호라는 결론의 근거. 본 연구의 지수부 제한 실험(4.9절)과 방향 일치
Lange 외 2024 [20]	float32 U-Net(구름 검출), 단일 플립 19,800회	지수부 플립만 큰 피해, 가수부 무시 가능. 예: $12.38 \to 5.3 \times 10^{10}$	우주 응용에서 같은 관찰
Stutz 외 2021 [9]	int8 양자화 CIFAR-10, 비트당 무작위 오류율	일반 학습: BER 0.1 %에서 오류 5.5 %(무손상 4.3 %), 1 %에서 32 %. 가중치 클리핑 0.1: BER 1 %에서 8.9 %	float32인 본 연구는 BER 0.031 %($p = 1\,\%$)에서 이미 정확도 15.4 %. int8이 float32보다 훨씬 강건. "클리핑만으로도 효과적"이라는 결론은 H3과 같음
Hoang 외 2020 [7]	float32 ResNet-18 ImageNet, 활성값 클리핑	BER 10^{-5}에서 무방어는 찍기 수준, 클리핑은 소폭 손실	BER 10^{-5}는 $p \approx 0.032\,\%$. 본 연구 모델은 이 지점에서 생존률 0.6. 모델이 클수록 같은 BER에 명중 수가 많아 먼저 붕괴
Cai 외 2024 [21]	LeNet-5 가중치에 무작위 SEU, 가중치 제한 + 치명 비트만 TMR	가중치 제한이 SEU 수가 적을 때 치명 결과를 거의 제거. 선택적 TMR로 전체 TMR 대비 자원 99.3 % 절감	가중치 제한은 본 연구의 클리핑과 같은 방어. 본 연구는 이를 13단계 선량에 걸친 p–정확도 곡선으로 확장

세 가지가 일관된다. 첫째, float32 가중치의 피해는 지수 최상위 비트의 $0 \to 1$ 플립에 집중되며, 이것이 본 연구의 이봉 분포와 Hong 외의 "약 절반의 파라미터가 취약"이라는 관찰을 동시에 설명한다. 둘째, 값의 범위를 제한하는 방어(활성값 클리핑, 가중치 클리핑, 범위 제한)는 모든 연구에서 가장 비용이 낮으면서 효과가 큰 방어로 나타났다. 셋째, int8 양자화 모델은 지수부가 없어 같은 BER에서 float32보다 훨씬 강건하므로, 탑재용 신경망에는 양자화 자체가 방어가 된다. 본 연구의 기여는 이 관찰들을 13단계 선량에 걸친 p–정확도 곡선과 생존률로 정량화하고, 가중치 수가 110배 차이 나는 네 모델에서 생존이 확률이 아니라 명중 수로 결정됨을 보였으며, 궤도 측정 SEU 율을 통해 모델 크기별 노출 시간으로 환산한 데 있다. Hong 외 [8]가 "취약 파라미터의 비율"이 모델 크기와 무관하다고 보고한 것과, 본 연구의 "k_{50}이 모델 크기와 무관하다"는 결과는 같은 사실의 두 표현이다.

5.4 한계

- **stress 모드는 시간이 없다.** LEO 일수 환산은 기대 명중 수만 맞춘 것이며, SAA 통과처럼 명중이 시간적으로 몰리는 효과, 추론 중간에 명중이 들어오는 효과는 반영하지 않았다.
- **r은 두 위성의 측정값으로 고정하였다.** $r = 10^{-6}$/bit/day는 Alsat-1(686 km)과 JASON-2(1,336 km)의 상용 메모리 측정값 [13–15] 범위 안에 있으나, 실제 SEU 율은 소자·고도·차폐·태양 활동에 따라 수 자릿수 범위로 달라진다 [3]. 특히 업셋의 80 % 이상이 SAA 통과 중에 생기고, 400 km급 궤도는 JASON-2보다 환경이 온화하며, 최신 DRAM은 훨씬 낮은 값이 보고되기도 한다.
- **가중치만 뒤집었다.** 활성값·그래디언트·옵티마이저 상태·명령어 메모리의 비트플립과 다중

비트 오류(MBU), 총이온화선량(TID)은 다루지 않았다.

- **자료형이 하나이고, 큰 모델은 정확도가 낮다.** float32만 실험하였다. 실제 탑재용 신경망은 int8 양자화를 흔히 쓰며, 정수형에서는 지수부가 없어 결과가 달라질 수 있다. 또한 `cifar_deep`과 `resnet18_t10`은 CPU 예산 때문에 무손상 정확도가 54.6 %, 39.1 %에 그쳐, 생존률은 무손상 대비로 재더라도 "여유가 작은 모델"의 결과로 읽어야 한다. 충분히 학습된 ResNet-18(정확도 90 % 이상)에서는 클리핑의 이득이 더 클 수 있다.
- **반복 10회, CIFAR 평가 2,000장.** 생존률의 95 % 신뢰구간이 넓다(10회 중 6회 생존이면 대략 0.3–0.85). p_{50}의 추정값도 보간에 의존한다. 또한 `cifar_deep`·`resnet18_t10`의 정확도는 시험 2,000장으로 잰 것이라 시행 하나의 정확도에 약 ± 1 %p(정확도 40–70 %에서 표준오차 $\sqrt{a(1-a)/2000} \approx 1.0$–$1.1$ %p)의 표본 오차가 있다. 조건 간 비교에는 같은 2,000장을 쓰므로 영향이 작지만, 무손상 정확도의 90 %라는 생존 기준 근처의 시행은 표본 오차만으로 생존/비생존이 갈릴 수 있다.
- **클리핑 상수** $C = 3$은 조정하지 않았다. 학습된 가중치의 분포에 맞춰 C를 정하면 결과가 달라질 수 있다.
- **수학 모델의 범위.** 모델 A는 "치명 명중이 하나라도 있으면 실패"라는 단순화이며, 치명 명중 없이 가수부 손상이 쌓여 실패하는 경우(큰 k)는 모델 B에 맡겼다. α는 데이터로 맞춘 값이다. E5의 이득은 `mnist_linear` 한 모델에서 잰 것이다.

6 결론 및 향후 연구

float32 신경망의 가중치에 진짜 비트플립을 주입한 결과, (1) 정확도는 비트플립 확률에 대해 임계 구간을 갖고 무너지며(H1, H2), (2) 같은 선량에서도 지수부 명중 여부에 따라 결과가 두 무리로 갈라지고, (3) NaN/∞를 잘라내는 클리핑만으로 생존 가능한 선량이 약 102배 늘어나며(H3), (4) 가중치 수가 110배 차이 나는 네 모델에서 생존을 결정하는 것은 확률 p가 아니라 명중 수 k이고 ($k_{50} \approx 60$–110), 따라서 궤도에서 버티는 시간은 모델 크기에 반비례한다(17일 $\rightarrow$ 7.5시간; H5). (5) 이 관계는 치명 확률 q 하나로 요약되는 수식 $S = \exp(-q\, r N_{\mathrm{bits}} T)$로 표현되며, $q \approx \frac{1}{32}\pi_+ \alpha$로 모델의 구조에서 거의 계산되고, 맞추지 않은 궤도 모드 데이터를 평균 오차 0.06로 예측한다(H4). (6) 단일 비트 실험은 32비트 가운데 bit 30만 치명적임을 보였고, 그 생존률은 $1 - 32q$로 네 모델 모두 예측되었다. (7) 방어 6종 가운데 패리티는 가중치의 20 %가 지워져도 무손상, TMR은 유도식 $k_{50} \approx \sqrt{32 N_w \ln 2/(3q)}$가 예측한 선량 부근에서 무너지며, 클리핑은 이득 약 100배(여유가 작은 과제에서 10–15배), 로짓 중앙값 앙상블은 2배, 로짓 평균 앙상블은 오히려 해롭다. 실용적 함의는 분명하다. 탑재 모델이 클수록 방어는 선택이 아니라 필수이며, 최소한 가중치 클리핑을 켜야 하고, 더 나아가 지수부 비트만 선택적으로 보호(패리티·TMR)하는 것이 전체 비트를 보호하는 것보다 비용 대비 효과가 클 것으로 예상된다. 클리핑의 이득이 여유가 작은 모델에서 줄어든다는 결과는, 클리핑을 지수부 보호와 함께 써야 하는 이유이기도 하다.

향후 연구로 다음을 계획한다.

1. **E2 비트별 치명도**: bit 31, 30, 29, 27, 23, 22, 10, 0을 각각 정확히 한 번 뒤집어 "비트 지도"를 작성하고, 지수부 선택 보호의 근거를 정량화한다.
2. **학습 중 주입**: 본 논문은 학습이 끝난 가중치에 대한 추론만 다루었다. SGD 학습 도중에 명중이 들어오면 거대 로짓이 손실을 ∞, 그래디언트를 NaN으로 만들어 실패의 모양이 달라질 수 있고, 반대로 이어지는 SGD 스텝이 클리핑된 가중치를 다시 고칠 수도 있다. 궤도상 재학습(on-orbit fine-tuning)의 가능 여부는 별도 실험으로 다룬다.
3. **방어의 비용**: 패리티(메모리 +3 %), TMR(+200 %), 앙상블(+400 %)의 메모리·연산 비용을 이득 G_d와 함께 제시하고, 지수부 비트만 보호하는 선택적 패리티·TMR의 이득을 측정한다.

4. **모델 B의 기계론적 해석**: 클리핑 조건의 k_{50}이 과제의 여유(클래스 간 로짓 차이)로 예측되는지 확인한다.

5. **자료형·학습 예산 확장**: int8 양자화 모델, 그리고 충분히 학습된(정확도 90 % 이상) CIFAR-10 모델에서 클리핑 이득이 회복되는지 확인한다.

재현성

전체 코드와 결과 CSV, 그림 생성 스크립트는 `https://github.com/SJinLee/AI-in-space`에 있다. E1 결과는 다음 한 줄로 재현된다(CPU, 수 분).

```
python src/simulate.py --model mnist_linear --mode infer --rad stress \
    --p 0.001 --defense none --trials 10
```

13개의 p와 두 방어를 일괄 실행하는 셀은 `src/seu_suite_colab.ipynb` 3-1절에, 모델 크기 축(E1-M), 궤도 모드(E3, `--rad leo_saa --T-list ...`), 방어 비교(E5, `--defenses none clip tmr ensemble ensemble_median parity`)는 모두 `src/run_e1_models.py` 하나로 실행하며(CPU로 모델당 2–9분), 본 논문의 모든 그림·표·본문 수치와 수학 모델의 적합(`paper/model_fit.py`)은 `python paper/make_figures.py`가 CSV에서 다시 계산한다.

참고문헌

[1] R. C. Baumann, "Radiation-induced soft errors in advanced semiconductor technologies," *IEEE Transactions on Device and Materials Reliability,* vol. 5, no. 3, pp. 305–316, 2005.

[2] E. Normand, "Single-event effects in avionics," *IEEE Transactions on Nuclear Science,* vol. 43, no. 2, pp. 461–474, 1996.

[3] J. L. Barth, C. S. Dyer, and E. G. Stassinopoulos, "Space, atmospheric, and terrestrial radiation environments," *IEEE Transactions on Nuclear Science,* vol. 50, no. 3, pp. 466–482, 2003.

[4] G. Li, S. K. S. Hari, M. Sullivan, T. Tsai, K. Pattabiraman, J. Emer, and S. W. Keckler, "Understanding error propagation in deep learning neural network (DNN) accelerators and applications," in *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis* (*SC '17*), 2017.

[5] B. Reagen, U. Gupta, L. Pentecost, P. Whatmough, S. K. Lee, N. Mulholland, D. Brooks, and G.-Y. Wei, "Ares: A framework for quantifying the resilience of deep neural networks," in *Proceedings of the 55th Design Automation Conference* (*DAC*), 2018.

[6] Z. Chen, G. Li, K. Pattabiraman, and N. DeBardeleben, "BinFI: An efficient fault injector for safety-critical machine learning systems," in *Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis* (*SC '19*), 2019.

[7] L.-H. Hoang, M. A. Hanif, and M. Shafique, "FT-ClipAct: Resilience analysis of deep neural networks and improving their fault tolerance using clipped activation," in *Design, Automation & Test in Europe Conference* (*DATE*), 2020.

[8] S. Hong, P. Frigo, Y. Kaya, C. Giuffrida, and T. Dumitraş, "Terminal brain damage: Exposing the graceless degradation in deep neural networks under hardware fault attacks," in *Proceedings of the 28th USENIX Security Symposium*, 2019, pp. 497–514.

[9] D. Stutz, N. Chandramoorthy, M. Hein, and B. Schiele, "Bit error robustness for energy-efficient DNN accelerators," in *Proceedings of Machine Learning and Systems* (*MLSys*), vol. 3, 2021.

[10] IEEE, "IEEE standard for floating-point arithmetic," IEEE Std 754-2019, 2019.

[11] R. E. Lyons and W. Vanderkulk, "The use of triple-modular redundancy to improve computer reliability," *IBM Journal of Research and Development,* vol. 6, no. 2, pp. 200–209, 1962.

[12] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems 32*, 2019.

[13] Y. Bentoutou and M. Djaifri, "Observations of single-event upsets and multiple-bit upsets in random access memories on-board the Algerian satellite," in *2008 IEEE Nuclear Science Symposium Conference Record*, 2008, pp. 2568–2570.

[14] A. Samaras, B. Vandevelde, N. Sukhaseum, N. Chatry, A. Rodriguez, F. Wrobel, F. Bezerra, E. Lorfevre, and R. Ecoffet, "CARMEN1 and CARMEN2 experiment: Comparison between in-flight measured SEE rates and predictions," in *Proceedings of the European Conference on Radiation and Its Effects on Components and Systems* (*RADECS*), 2015.

[15] M. Wang, H. Qiu, L. Xu, D. Wang, Y. Li, T. Zhang, J. Liu, and H. Li, "A case for application-aware space radiation tolerance in orbital computing," arXiv:2407.11853, 2024.

[16] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE,* vol. 86, no. 11, pp. 2278–2324, 1998.

[17] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (*CVPR*), 2016, pp. 770–778.

[18] TorchVision maintainers and contributors, "TorchVision: PyTorch's computer vision library, ResNet18_Weights.IMAGENET1K_V1," https://github.com/pytorch/vision, 2016.

[19] Z. Yan, Y. Shi, W. Liao, M. Hashimoto, X. Zhou, and C. Zhuo, "When single event upset meets deep neural networks: Observations, explorations, and remedies," arXiv:1909.04697, 2019.

[20] K. Lange, F. Fontana, F. Rossi, M. Varile, and G. Apruzzese, "Machine learning in space: Surveying the robustness of on-board ML models to radiation," arXiv:2405.02642, 2024.

[21] Y. Cai, M. Cai, Y. Wu, J. Lu, Z. Bian, B. Liu, and S. Cui, "Evaluation and mitigation of weight-related single event upsets in a convolutional neural network," *Electronics,* vol. 13, no. 7, p. 1296, 2024.

A 시행 CSV의 열

열	뜻
`seed`	해당 시행의 난수 시드(마스터 시드 2026에서 유도)
`acc`, `crashed`	시험 정확도(%), NaN/∞ 발생 여부
`k`, `n_exponent_hits`, `n_sign_hits`	명중 수, 그중 지수부(23–30)·부호(31) 명중 수
`n_bits`, `p`, `T_days`, `r`	뒤집을 수 있는 비트 수, 조작 변수
`allowed_bits`, `single_hit`	허용 비트 제한, 단일 명중 여부(E2용)
`clean_acc`, `last_finite_acc`	무손상 정확도, 붕괴 전 마지막 유한 정확도

B 시행별 원자료

표 2의 각 조건에 대한 10회 시행의 정확도는 저장소의 `src/results/single_mnist_linear_infer_stress_none_p*.csv` 및 같은 이름의 `clip` 파일에 있다. 예를 들어 방어 없음 $p = 0.1\,\%$의 10회는 47.3, 45.8, 96.6, 78.1, 96.6, 33.2, 96.1, 96.6, 56.8, 40.7 %이다.